TP555 - Inteligência Artificial e Machine Learning:

Redes Neurais Artificiais (Parte I)

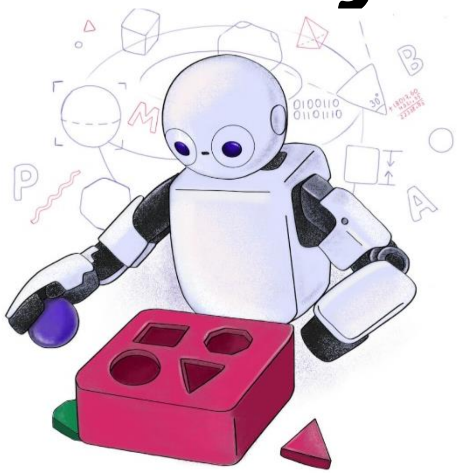

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Redes Neurais Artificiais

- Redes neurais artificiais (RNAs) são modelos computacionais inspirados pelo funcionamento do cérebro dos animais.
- Elas são capazes de realizar aprendizado de máquina bem como o reconhecimento de padrões.
- RNAs são geralmente apresentadas como sistemas de ***neurônios interconectados***, que podem computar valores de saída, simulando o comportamento de redes neurais biológicas.
- Esta primeira parte da aula foca nos elementos básicos de uma rede neural, os ***neurônios***.

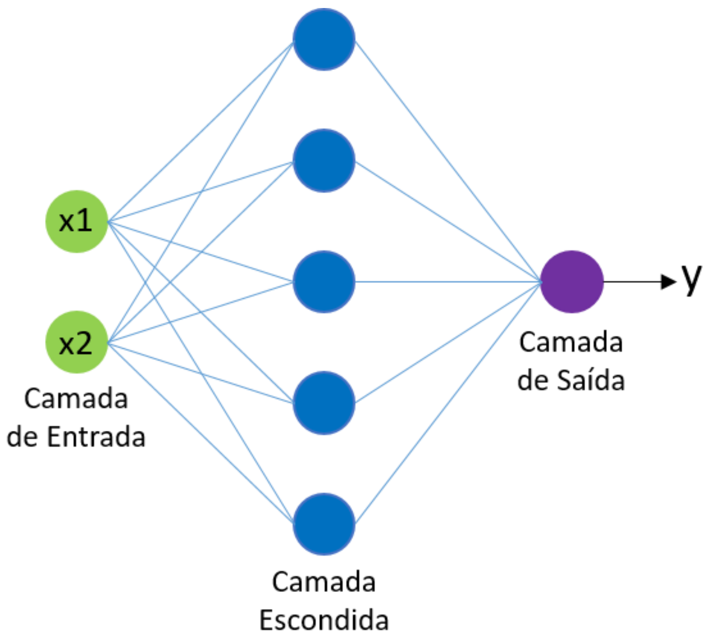

Algumas aplicações famosas

- RNAs são versáteis, poderosas e escalonáveis, tornando-as ideais para realizar tarefas grandes e altamente complexas de ***aprendizado de máquina***, como por exemplo classificar bilhões de imagens (por exemplo, Google Images), serviços de reconhecimento de fala (por exemplo, o Siri da Apple, Alexa da Amazon e Google Assistant da Google), recomendar os melhores vídeos a centenas de milhões de usuários todos os dias (por exemplo, YouTube) ou aprender a vencer o campeão mundial de Go examinando milhões de jogos anteriores e depois jogando contra si mesmo (AlphaGo do DeepMind).

Alexa

Google Assistant

Siri

Um pouco de contexto

- A descoberta da célula em 1665 por Robert Hooke foi importantíssima para que houvesse uma melhor compreensão da estrutura dos seres vivos.
- Podemos considerar a célula como sendo o "***átomo da vida***".
- As células ***eucariontes*** possuem três partes principais: membrana, núcleo e citoplasma. A membrana "delimita a célula", i.e., ela isola seu interior do meio externo. Já o núcleo abriga o material genético e, no citoplasma, estão componentes como as organelas.
- ***Neurônios*** são células também, mas são células que possuem mecanismos elétricos e/ou químicos característicos. A figura ao lado mostra o diagrama de um ***neurônio***.

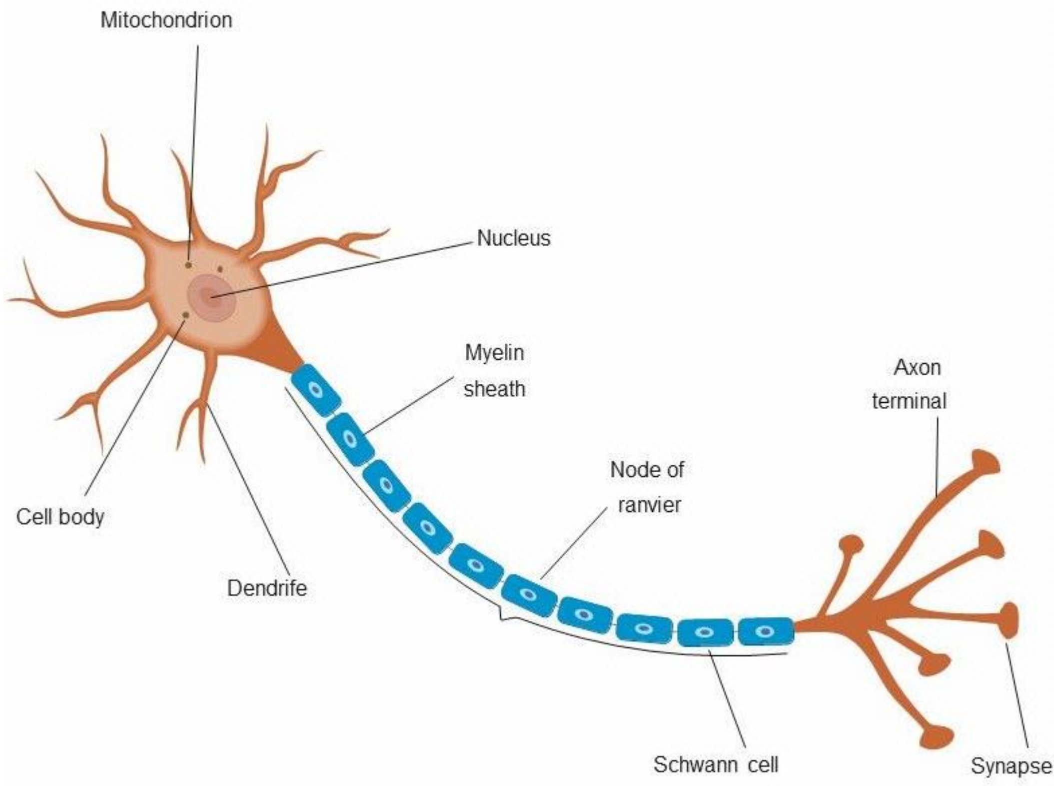

Um pouco de contexto

- Em termos simples, mas lembrando de que há exceções, nós podemos afirmar que:
  - O neurônio recebe estímulos elétricos, basicamente a partir dos dendritos.
  - Esses estímulos são integrados.
  - A integração dos estímulos pode levar à geração ou não de uma resposta elétrica enviada pelo axônio.
- Do ponto de vista do nosso curso, o ***neurônio*** será um sistema com várias entradas e uma saída.
- Nós podemos simplificar o funcionamento do ***neurônio*** como:
  - Os neurônios recebem estímulos elétricos.
  - Esses estímulos são integrados.
  - Se a atividade (i.e., integração dos estímulos) exceder certo limiar, o ***neurônio*** gera um pulso (ou potencial de ação).
- O potencial de ação é mostrado na figura ao lado.
- Um ***neurônio*** se conecta com 10 a 100000 outros ***neurônios*** através das ***sinapses***.
- Sinais são passados de ***neurônio*** para ***neurônio*** através de reações eletro-químicas.

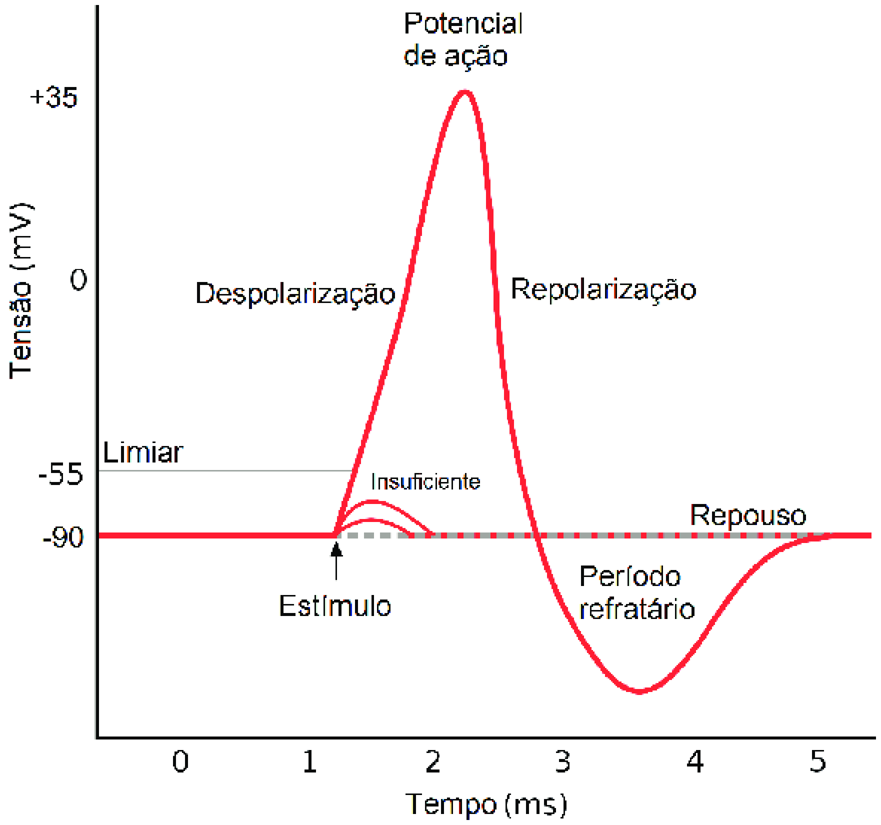

O Modelo de McCulloch e Pitts

- A figura ao lado mostra o modelo matemático do ***neurônio*** criado por McCulloch e Pitts em 1943.
- A grosso modo, o ***neurônio*** é ativado (ou disparado) quando uma ***combinação linear*** de suas entradas excede um ***limiar de ativação***.
- Ou seja, um ***neurônio*** nada mais é do que um ***classificador linear*** que vimos anteriormente.
- As premissas do modelo do ***neurônio*** de McCulloch e Pitts (M-P) são:
  - Os valores das entradas, $x_i, \forall i$, ou também chamadas de ***sinapses***, são sempre valores booleanos, i.e., ‘0’, ou ‘1’.
  - As entradas são simplesmente somadas.
  - A atividade do ***neurônio*** é um processo do tipo “tudo ou nada”, ou seja, um processo binário. Portanto, a ***função de ativação*** do neurônio é uma ***função degrau*** com ***ponto de disparo*** dependente do ***limiar de ativação***, θ**.**
  - Um certo número de ***sinapses*** deve ser excitado num determinado período para que o neurônio “dispare”.

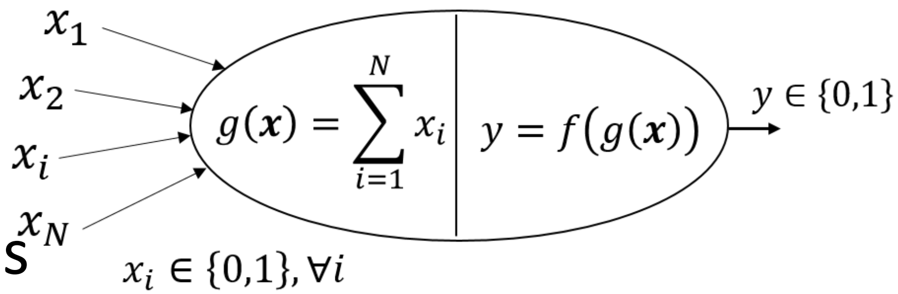

$$y = f(g(\boldsymbol{x})) = \begin{cases} 1, \text{se } g(\boldsymbol{x}) \geq \theta \\ 0, \text{se } g(\boldsymbol{x}) < \theta \end{cases}$$

onde θ é o ***limiar de ativação***.

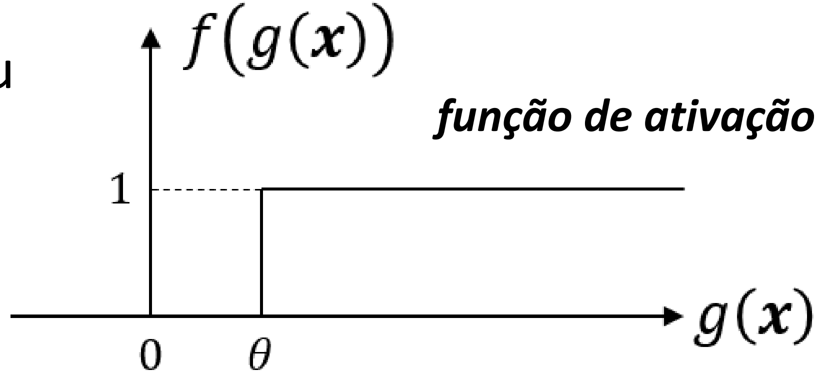

Exemplos com o neurônio de McCulloch e Pitts

OR			
x1	x2	y	$g(\boldsymbol{x})$
0	0	0	0
0	1	1	1
1	0	1	1
1	1	1	2

- Qual seria o valor do ***limiar de ativação***, θ?
- Analisando-se $g(\boldsymbol{x})$, vemos que o disparo deve ocorrer quando $g(\boldsymbol{x}) \geq 1$, portanto, $\theta = 1$.

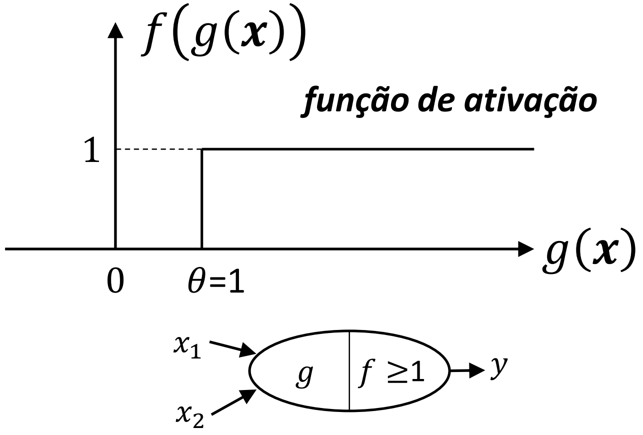

AND			
x1	x2	y	$g(\boldsymbol{x})$
0	0	0	0
0	1	0	1
1	0	0	1
1	1	1	2

- Qual seria o valor do ***limiar de ativação***, θ?
- Analisando-se $g(\boldsymbol{x})$, vemos que o disparo deve ocorrer quando $g(\boldsymbol{x}) \geq 2$, portanto, $\theta = 2$.

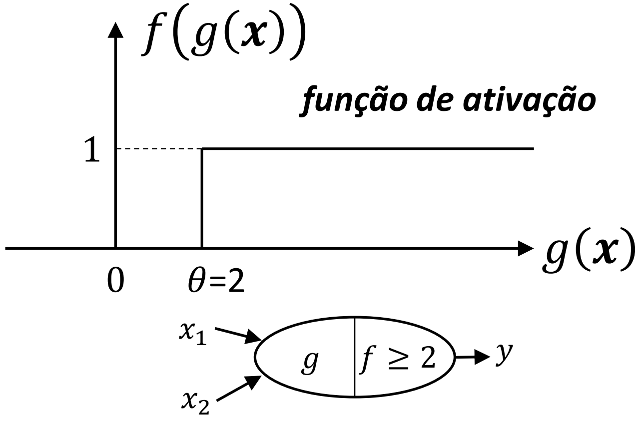

NOT		
x1	y	$g(\boldsymbol{x})$
0	1	0
1	0	1

- Qual seria o valor do ***limiar de ativação***, θ?
- Analisando-se $g(\boldsymbol{x})$, vemos que para o disparo occorer, o valor de x1 deve ser negado, e assim, ele ocorre quando $g(\boldsymbol{x}) \geq 1$, portanto, $\theta = 1$.

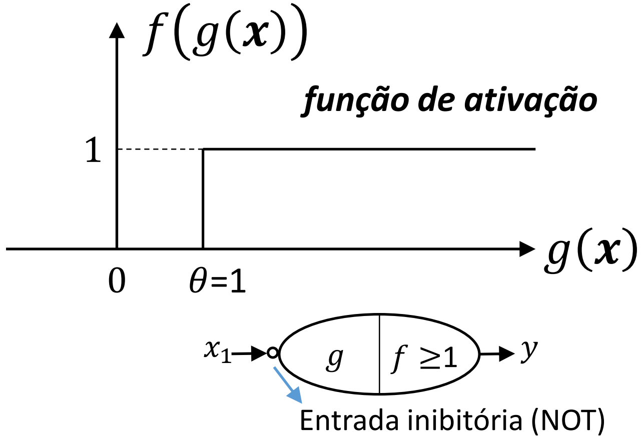

Perceptron

- Em 1958, Frank Rosenblatt, propôs o modelo clássico do ***perceptron***.
- Em 1969, o modelo de Rosenblatt foi refinado e cuidadosamente analisado por Minsky e Papert. O modelo criado por eles é chamado de ***perceptron***. O modelo proposto por eles é mostrado na figura ao lado.
- O modelo **perceptron**, é um modelo computacional mais geral que o modelo do ***neurônio*** de M-P.
- Esse novo modelo supera algumas das limitações do modelo de M-P, introduzindo o conceito de ***pesos sinápticos*** (uma medida de importância dos atributos) para as entradas (ou ***sinapses***) e um método para aprender esses ***pesos***. Além disso, as entradas não são mais limitadas a valores booleanos, como no caso do modelo de M-P, suportando entradas reais, o que torna este modelo mais útil e generalizado.
- Assim como no modelo de M-P, a ***função de ativação*** utilizada pelo ***perceptron*** também é a ***função degrau*** com a diferença que aqui ela não mais depende do ***limiar de ativação*** θ.

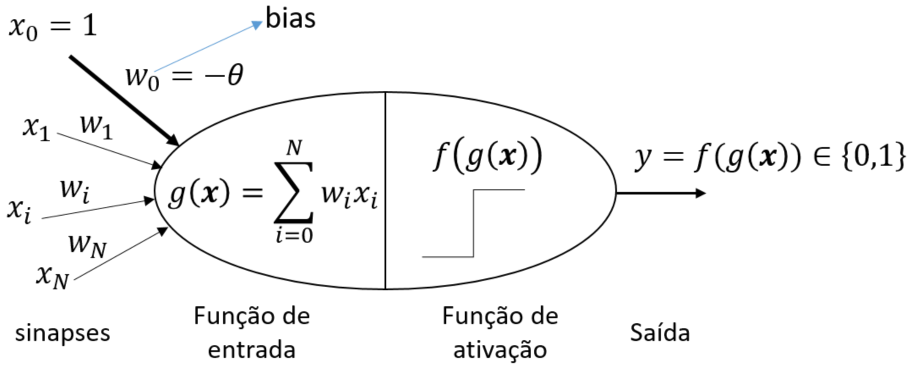

$$y = f(g(\boldsymbol{x})) = \begin{cases} 1, \text{se } g(\boldsymbol{x}) \geq 0 \\ 0, \text{se } g(\boldsymbol{x}) < 0 \end{cases}$$

Perceba que o ***limiar de ativação*** θ agora faz parte das entradas e é chamado de ***bias***.

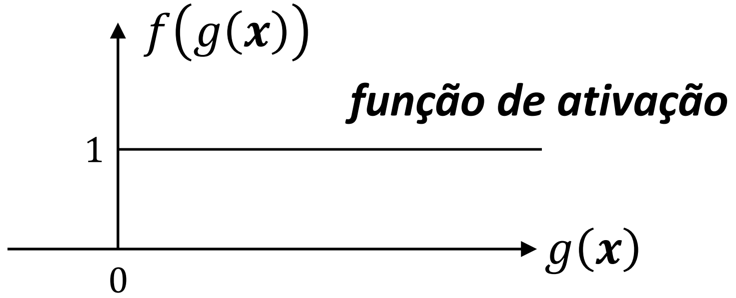

Perceptron

- A ideia é que a ativação do ***perceptron*** (causada pelos estímulos de entrada) seja uma ***combinação linear*** entre os ***estímulos*** e os ***pesos sinápticos***. Se essa ativação exceder certo ***limiar de ativação***, ocorrerá o ***disparo***. Isso pode ser expresso por meio de uma ***função de ativação*** do tipo ***degrau***.
- Note que a ***função de ativação*** $f(.)$ está centrada "em torno de zero" e o ***limiar de ativação*** (ou ***disparo***) é controlado, indiretamente, pelo valor do ***peso do bias***, w_0.
- O tipo de resposta do ***perceptron*** dá origem a um ***classificador*** para ***problemas com duas classes***. As classes são separadas por uma ***fronteira de decisão*** para o qual a equação abaixo é verdadeira.

$$\sum_{i=0}^{N} w_i x_i = 0.$$

- No ***espaço dos atributos*** $x_i, \forall i$, essa é a equação de um ***hiperplano***.
- Portanto, um ***perceptron*** só é capaz de ***classificar*** dados que sejam ***linearmente separáveis*** (ou seja, separáveis por um ***hiperplano***).
- O ***perceptron*** convergirá apenas se o conjunto de dados for ***linearmente separável***. A figura ao lado ilustra isso para um caso bidimensional.
- Observe que, ao contrário dos ***classificadores de regressão logística***, os ***perceptrons*** não produzem como saída uma probabilidade de classe, em vez disso, eles apenas fazem previsões com base em um ***limiar rígido***, i.e., 0 ou 1. Essa é uma das razões para se preferir a ***regressão logística*** ao invés do ***perceptron***.

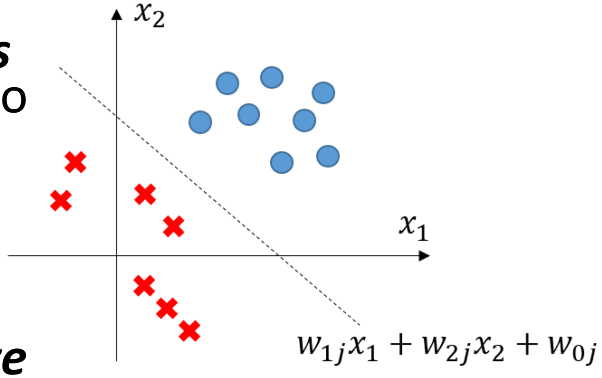

Regra de aprendizado do perceptron

- Como discutimos anteriormente, a ***função degrau*** tem derivada igual a 0 em todos os pontos, exceto em torno de 0, onde ela é indefinida. Portanto, nós não podemos utilizar o ***gradiente descentende*** para treinar o ***perceptron***.
- Existe, porém, uma regra simples de atualização dos ***pesos*** que converge para uma solução, ou seja, um ***separador linear*** que ***classifica*** os dados perfeitamente, dado que eles sejam ***linearmente separáveis***.
- Portanto, caso os dados sejam ***linearmente separáveis***, a ***regra de aprendizado do perceptron*** tem convergência garantida num número finito de iterações. Nessa regra, para cada exemplo do conjunto de treinamento, obtém-se, primeiramente, a saída do ***perceptron*** para os ***pesos sinápticos*** atuais:

$$y = f\left(\sum_{i=0}^{N} w_i x_i\right) = f(\boldsymbol{w}^T \boldsymbol{x}).$$

- Em seguida, calcula-se o erro entre a saída y do ***perceptron*** e o rótulo d do exemplo:

$$e = d - y.$$

- Caso o erro não seja nulo, a ***equação de adaptação dos pesos sinápticos*** é definida da seguinte forma:

$$\boldsymbol{w} \leftarrow \boldsymbol{w} + \alpha e \boldsymbol{x},$$

onde α é a ***taxa*** (ou ***passo***) ***de aprendizagem***.

- Após a apresentação de todos os exemplos de treinamento (ou seja, uma ***época***), deve haver um ***embaralhamento*** dos exemplos e uma nova etapa de treinamento. No caso ótimo, quando a ***separação linear*** ocorrer, não haverá mais erros, e as ***regras de atualização*** calculadas não mais modificarão os ***pesos sinápticos***.
- **OBS**.: A ***regra de aprendizado do perceptron*** é, geralmente, aplicada a um exemplo de entrada por vez. Os exemplos são escolhidos aleatóriamente, assim como o que é feito com o ***gradiente descendente estocástico***.

Exemplo: Perceptron com SciKit-Learn

```
import numpy as np
from sklearn.linear_model import Perceptron
from sklearn.metrics import mean_squared_error

# Define the number of examples.
N = 1000

# Create dataset.
x1 = np.random.randint(0,2,N)
x2 = np.random.randint(0,2,N)

y = x1 & x2

x1 = x1 + 0.1*np.random.randn(N,)
x2 = x2 + 0.1*np.random.randn(N,)

x0 = np.ones((N,))
X = np.c_[x0,x1,x2]

# Instantiate and train perceptron.
per = Perceptron(random_state=42)
per.fit(X, y)

# Predict.
y_pred = per.predict(X)

# Calculate MSE.
error = mean_squared_error(y_pred, y)
```

Importa classe Perceptron.

Gera os rótulos à partir dos dados originais. Função lógica AND.

Adiciona ruído aos atributos de entrada

Cria vetor de 1s para o peso de bias.

Instancia e treina o Perceptron.

Realiza a predição.

Calcula erro quadrático médio.

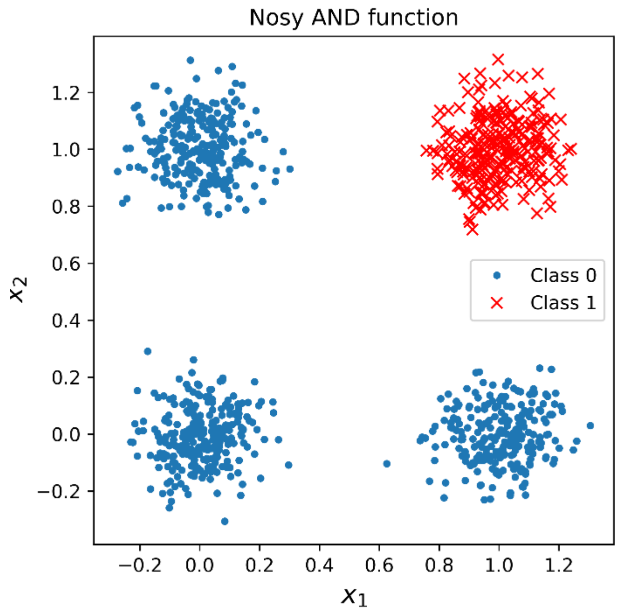

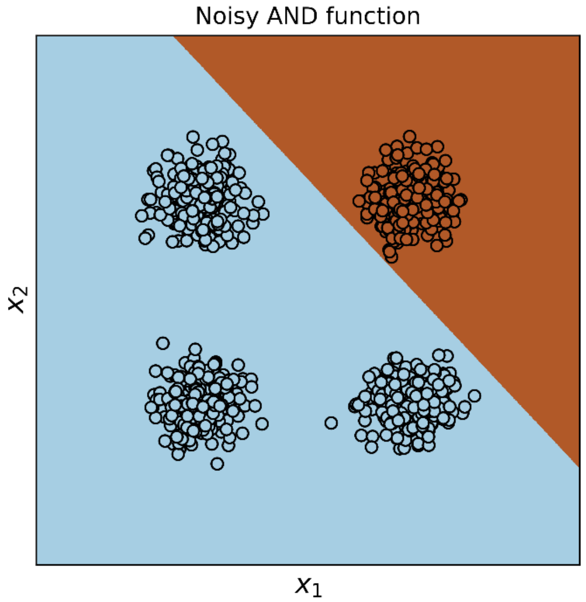

- Exemplo de classificação de dados ruidosos linearmente separáveis.
- A base de dados é gerada à partir da função de uma porta lógica AND.
- Como podemos ver, o perceptron classifica perfeitamente o conjunto de dados ruidosos.

Avisos

- Material já se encontra no site.

Obrigado!

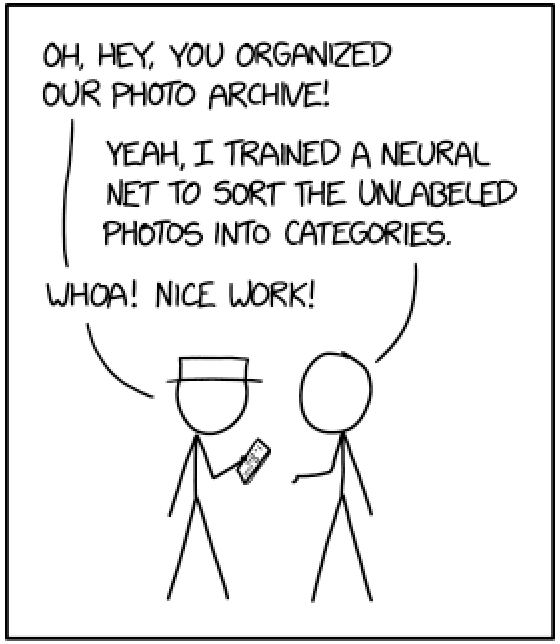

ENGINEERING TIP:
WHEN YOU DO A TASK BY HAND, YOU CAN TECHNICALLY SAY YOU TRAINED A NEURAL NET TO DO IT.

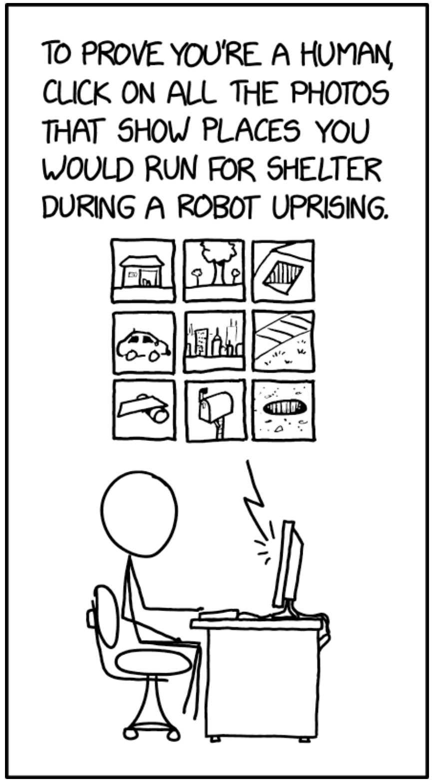

Figuras

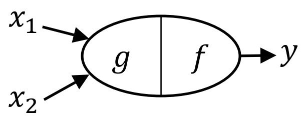

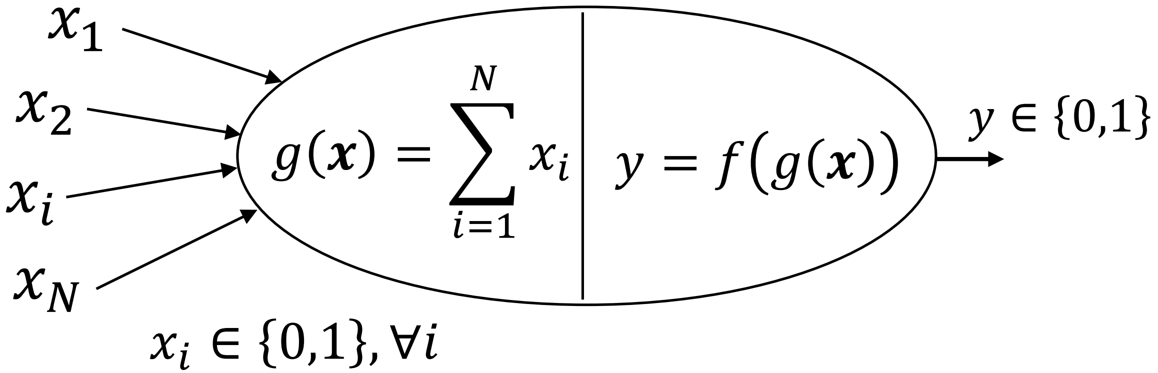

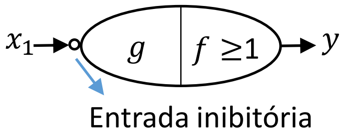

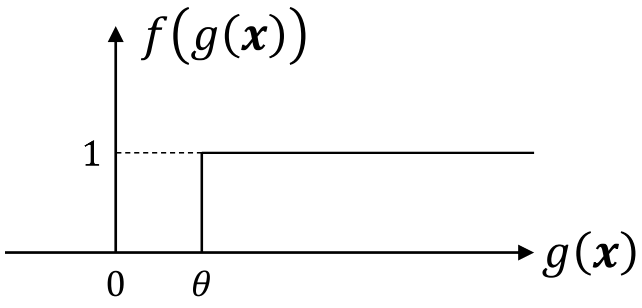

$$y = f\big(g(\boldsymbol{x})\big) = \begin{cases} 1 \text{ se } g(\boldsymbol{x}) \geq \theta \\ 0 \text{ se } g(\boldsymbol{x}) < \theta \end{cases}$$

onde θ é o limiar de decisão.

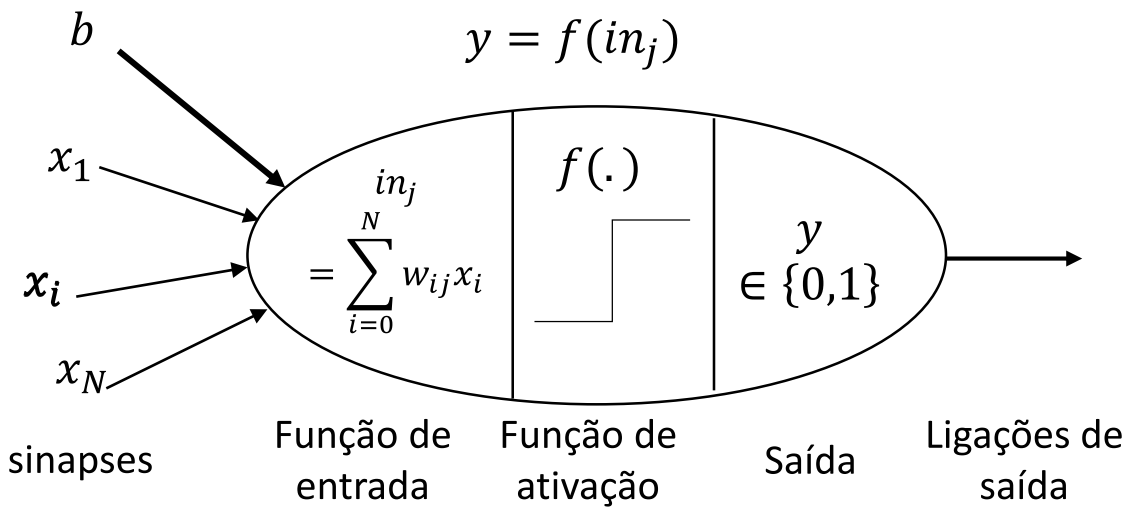
b
$y = f(in_j)$
x_1
x_i
x_N
$in_j = \sum_{i=0}^{N} w_{ij} x_i$
$f(.)$
$y \in \{0,1\}$
sinapses
Função de entrada
Função de ativação
Saída
Ligações de saída

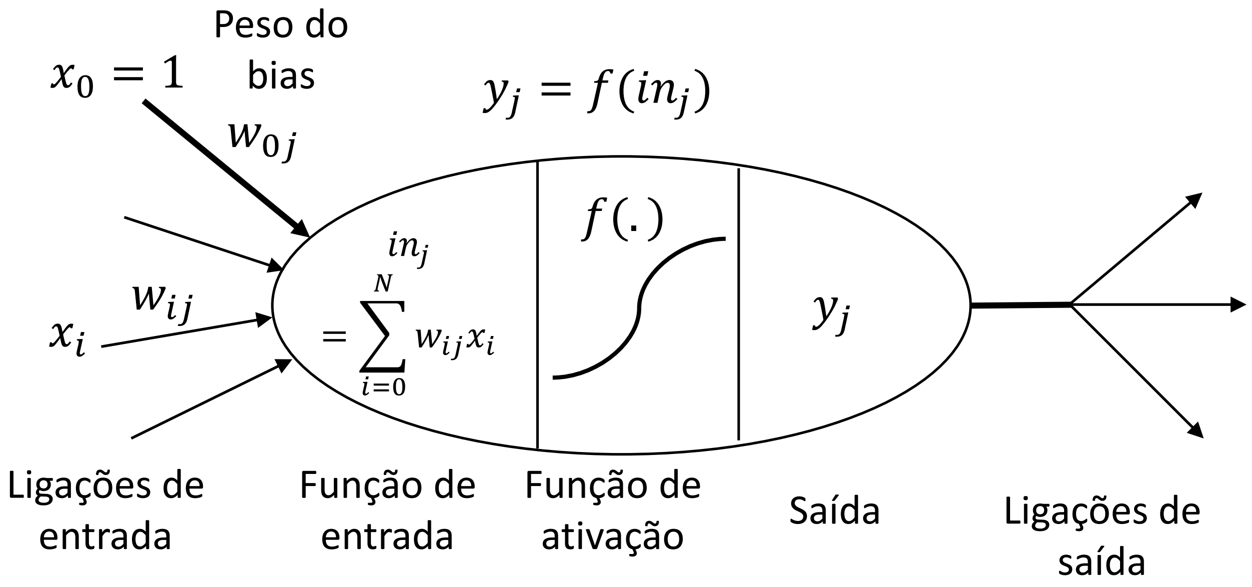

Peso do bias
$x_0 = 1$
w_{0j}
$y_j = f(in_j)$
w_{ij}
x_i
$in_j = \sum_{i=0}^{N} w_{ij} x_i$
$f(.)$
y_j
Ligações de entrada
Função de entrada
Função de ativação
Saída
Ligações de saída

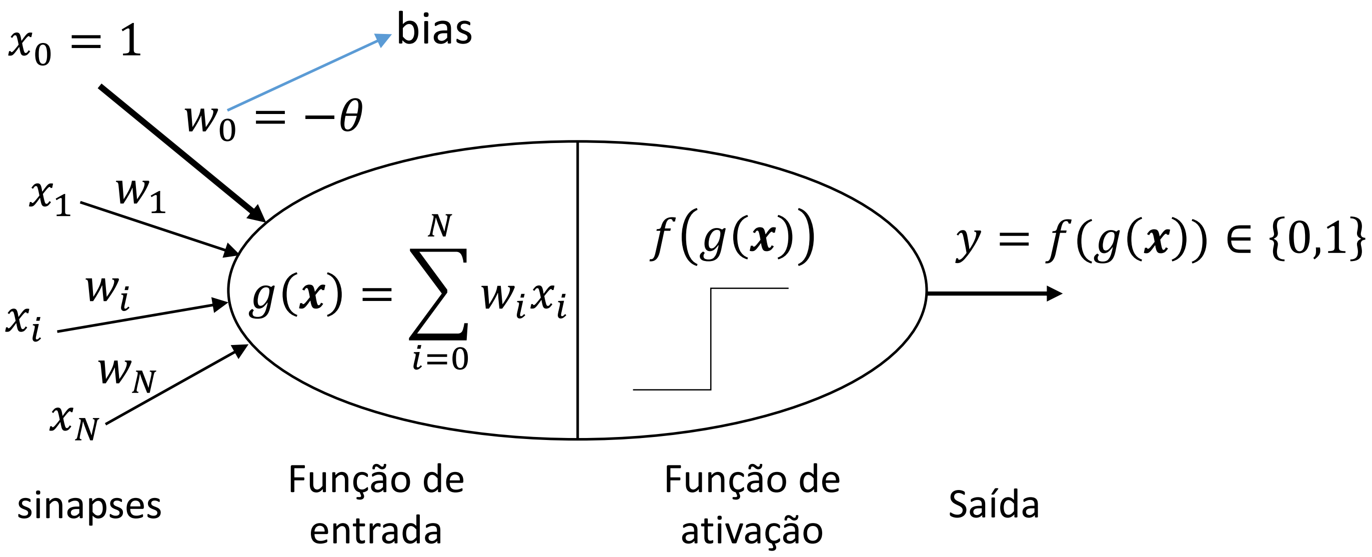

$x_0 = 1$
bias
$w_0 = -\theta$
x_1 w_1
x_i w_i
x_N w_N
$g(\boldsymbol{x}) = \sum_{i=0}^{N} w_i x_i$
$f(g(\boldsymbol{x}))$
$y = f(g(\boldsymbol{x})) \in \{0,1\}$
sinapses
Função de entrada
Função de ativação
Saída

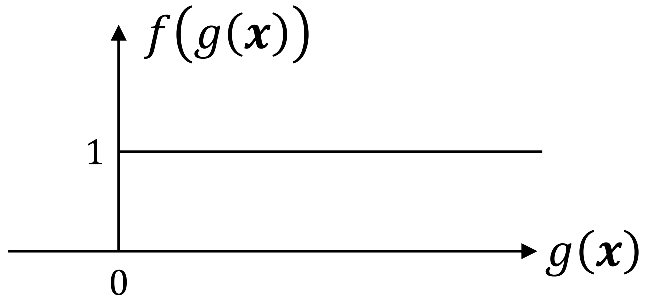

$f(g(\boldsymbol{x}))$
1
0
$g(\boldsymbol{x})$

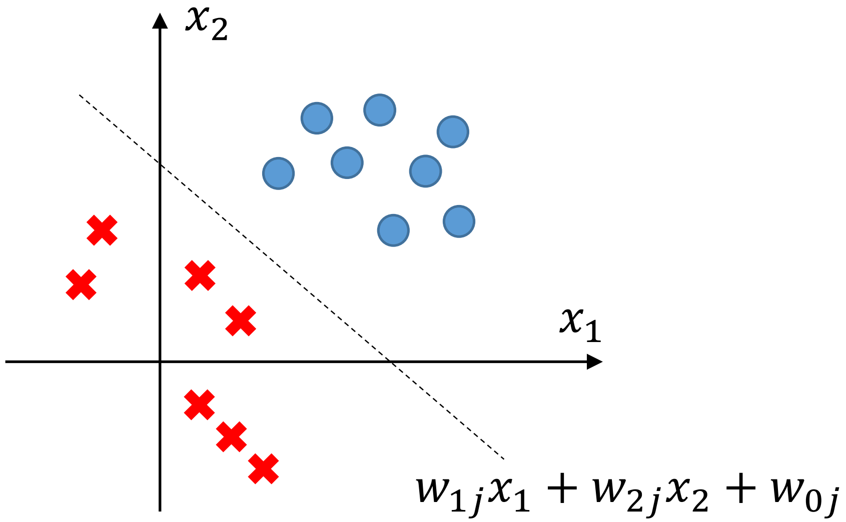
x_2
x_1
$w_{1j}x_1 + w_{2j}x_2 + w_{0j}$

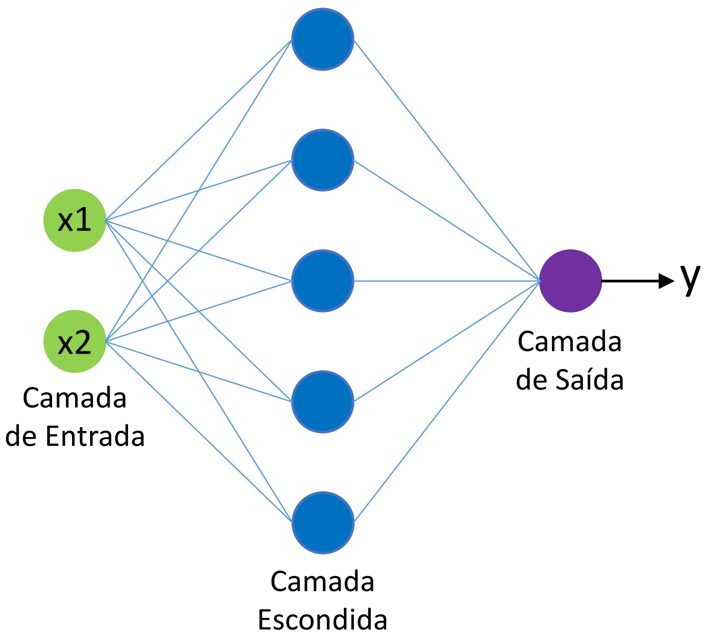
x1
x2
Camada
de Entrada
Camada
Escondida
Camada
de Saída
y