

TP555 - Inteligência Artificial e Machine Learning: *Introdução*



Inatel



Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- Introdução ao aprendizado de máquina.
- Como o próprio nome diz, é um curso introdutório onde veremos os conceitos básicos de funcionamento de vários ***algoritmos de aprendizado de máquina*** ou do Inglês, ***machine learning*** (ML).
- Não nós aprofundaremos nos conceitos matemáticos envolvidos.
- Porém, precisamos conhecer Python e alguns conceitos de álgebra linear e estatística.


Objetivo do curso

- O objetivo principal do curso é apresentar à vocês
 - os conceitos fundamentais da teoria por trás do aprendizado de máquina.
 - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir sobre os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Aplicar algoritmos de ML para a resolução de problemas.
 - Analisar e entender novos algoritmos de ML.
 - Criar seus próprios projetos.
- Compreender artigos científicos que utilizam ML.
- Realizar pesquisa que envolva ML e discutir os resultados obtidos.



Avaliação do Curso

- 2 Provas
 - Cada prova valerá 35% da nota (datas ainda serão definidas).
- Listas de Exercícios
 - 10% da nota.
 - Podem ser resolvidas em grupo, mas cada aluno deve fazer entregas separadas.
 - Listas serão disponibilizadas ao final de cada tópico.
 - [Devem ser comitadas no GitHub e entregues no MS Teams.](#)
- Projeto Prático
 - 20% da nota.
 - Pode ser feito em grupo (já divididos).
 - Tema será escolhido por vocês.




Motivação

- **Pesquisa:** algoritmos de ML tem um grande potencial para solucionar problemas em várias áreas tais como a de jogos, transportes, segurança, saúde, tecnologia, varejo, finanças, etc. Portanto, o emprego de ML em problemas destas áreas pode gerar pesquisas inovadoras.
 - Já se prevê que ML terá um papel importante no desenvolvimento da próxima geração de redes móveis e sem-fio (e.g., 6G).
- **Emprego:** grandes companhias (e.g., Google, Facebook, Amazon, etc.) usam ML para resolver os mais diversos tipos de problemas e assim aumentarem sua eficiência/lucros.







Um pouco de história

- A ideia de criar uma máquina pensante que imitasse as habilidades humanas é muito antiga, remontando à Grécia antiga.
- **Mitologia grega:** Talos, um autômato (máquina que realiza ações que lembram humanos ou animais) criado para proteger a princesa Europa de Creta de invasores.
- **300 A.C.:** Aristóteles almejava substituir a mão-de-obra escrava por objetos autônomos.
- **1822:** Charles Babbage cria os primeiros computadores mecânicos, as *máquinas diferencial* e *analítica*, se tornando o “pai dos computadores”.
- **1837:** Ada Lovelace escreve o primeiro programa de computador para a *máquina analítica* de Babbage, se tornando a primeira “programadora” conhecida.




Um pouco de história (continuação)

- **1847:** George Boole cria a lógica booleana, lançando as bases para a era da informação.
- **1943:** McCulloch e Pitts propõem um modelo matemático para o funcionamento de um neurônio. Lançando as bases para a criação das redes neurais artificiais.
- **1950:** Alan Turing cria o “*teste de Turing*”, que testa a capacidade de uma máquina em exibir comportamento inteligente indistinguível ao de um ser humano.
- **1952:** Arthur Samuel cria o primeiro programa de auto-aprendizagem (que mais tarde seria chamado de *aprendizado de máquina*) do mundo, o *Checkers-Player*, sendo a primeira demonstração do conceito de inteligência artificial.



Um pouco de história (continuação)

- **1956:** Surgimento da área de pesquisa em IA em um workshop no Dartmouth College nos EUA onde o termo IA foi cunhado por John McCarthy.
- **1958:** Frank Rosenblatt cria a primeira rede neural artificial, chamada de *Perceptron*.
- **1959:** Arthur Samuel cunha o termo *Aprendizado de Máquina* enquanto trabalhava na IBM.
- **1970-1980:** Devido a limitação dos computadores da época, IA atravessou alguns *invernos*, i.e., interesse e financiamentos na área diminuíram drasticamente.
- **1986:** Ascensão do aprendizado de máquina: surgimento de computadores mais poderosos, redes neurais retornam a popularidade com o algoritmo de *backpropagation* e grandes avanços em algoritmos e aplicações de ML.



Um pouco de história (continuação)

- **1997:** O supercomputador da IBM, chamado de *DeepBlue*, vence o campeão mundial de xadrez, Garry Kasparov.
- **2009:** O Google constrói o primeiro carro autônomo que dirige em áreas urbanas.
- **2011:** Outro supercomputador da IBM, chamado *Watson*, vence o show de perguntas e respostas *Jeopardy!*.
- **2011-2014:** Surgem assistentes pessoais, tais como *Siri*, *Google Now*, *Alexa* e *Cortana*, que utilizam reconhecimento de fala para responder questões e realizar tarefas simples.
- **2016:** O programa conhecido como *AlphaGo*, da empresa *DeepMind*, derrota o então 18 vezes campeão mundial de Go, Lee Sedol.
- **2018:** Universidades de todo o mundo começam a oferecer cursos de AI e ML.



Inatel

Inteligência + Artificial (IA)



- Vocês já pensaram sobre a definição destas duas palavras?
- **Inteligência:** é conjunto das *habilidades mentais* de **conhecer, compreender, aprender, resolver problemas e adaptar-se**.
 - Surgiu do Latim como união do prefixo *inter*: “entre” + sufixo *legere*: “escolha” => “entre escolhas”.
 - Ou seja, inteligência é a **capacidade de escolha** de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- **Artificial:** produzido pela mão do homem, não pela natureza, geralmente como uma cópia de algo natural.

Habilidades mentais desenvolvidas de forma não natural pela mão do homem.



Cópias de habilidades mentais humanas criadas de forma não natural pelo homem.

Definições e objetivo da IA

- **Definição:** *“Capacidade de um sistema de interpretar corretamente dados externos (vindos do ambiente), aprender com esses dados e usá-los para atingir tarefas e objetivos específicos por meio de adaptação flexível.” (Andreas Kaplan).*
- **Definição:** *“Ciência e engenharia de produzir máquinas inteligentes.” (John McCarthy).*
- **Objetivo:** Criar máquinas que **imitem** nossas **habilidades mentais**.
- Essa **imitação** é apenas uma aproximação pois ainda não conseguimos ter uma máquina que resolva diversos tipos de problemas (ensinados ou não) e nem criar matéria viva.
- É por isso que em IA fala-se da criação de máquinas que são **modelos aproximados** de nossas habilidades de aprender, raciocinar, enxergar, falar, ouvir, etc.

Inteligência Artificial

- IA é uma área muito ampla que **engloba** várias aplicações (ou sub-áreas ou objetivos) tais como
 - processamento de linguagem natural,*
 - representação do conhecimento,*
 - raciocínio automatizado,*
 - planejamento,*
 - visão computacional,*
 - robótica,*
 - aprendizado de máquina, que por sua vez engloba redes neurais artificiais, deep learning, etc. e*
 - inteligência artificial geral.*
- IA utiliza a **experiência** para adquirir **conhecimento** e também como aplicar esse conhecimento a problemas desconhecidos.
 - Exemplo:** Um problema matemático pode ser solucionado (i) caso ele tenha sido resolvido antes e sua solução **aprendida** ou (ii) caso ele nunca tenha sido visto antes mas um indivíduo com inteligência imagina (ou seja, pensa) possíveis maneiras de como resolve-lo baseado no que ele **sabe (conhecimento)**.




Algumas aplicações de IA



Algumas áreas onde IA é aplicada são:

- **Transporte:** veículos terrestres e aéreos autônomos, previsão do tráfego, etc.
- **Negócios:** recomendação de anúncios, produtos e conteúdos (e.g., netflix), chatbots para atendimento ao cliente, etc.
- **Educação:** pontuação automatizada de fala em testes de Inglês, correção de provas, chatbots para realização de matrículas, dúvidas, etc.
- **Clima:** previsão do tempo (temperatura, chuva, furacões, etc.).
- **Medicina:** detecção e/ou previsão de doenças (câncer, Alzheimer, pneumonia, COVID-19, etc.), chatbots que auxiliam no agendamento de consultas e respondem perguntas referentes a uma doença, descoberta de novas drogas, etc.
- **Finanças:** detecção de fraudes com cartão de crédito, previsão do comportamento do mercado de ações, etc.
- **Tecnologia:** filtros AntiSpam, “motores” de busca como o do Google, reconhecimento de fala, conversão de texto/fala e fala/texto, assistentes pessoais on-line (e.g., *Siri, Alexa*, etc.), tradução de textos.




Algumas Aplicações em Comunicações Digitais

- **Estimação de canal e detecção de sinais**
 - Ex.: IA estima o canal e detecta o símbolo transmitido conjuntamente, sem a necessidade de estimar o canal primeiro e depois detectar o símbolo transmitido.
- **Aprendizado de Sistemas de Comunicação de Ponta-a-Ponta**
 - Ex.: IA otimiza conjuntamente os blocos de processamento do Tx e Rx (estimação de canal, equalização, codificação/decodificação de canal, modulação/demodulação, etc.)
- **Comunicações em Ondas Milimétricas**
 - Ex.: IA é utilizada para prever bloqueios e realizar handovers proativos.
- **Alocação de Recursos**
 - Ex.: IA é empregada em redes IoT de baixa potência para entender o comportamento de dispositivos vizinhos e assim realizar a alocação de recursos com o intuito de evitar colisões, aumentando a vida útil das baterias e a taxa de dados úteis (goodput).
- **Rádio-sobre-Fibra**
 - Ex.: IA é utilizada para equalizar e detectar conjuntamente sinais transmitidos através de canais sem-fio e óticos, considerando conjuntamente os efeitos de ambos os canais.
- **Pré-distorção**
 - Ex.: IA é utilizada para aproximar uma equação que aumente a região linear de um amplificador de potência.
- **E vários outros tópicos.**





Exemplos interessantes do uso de IA

- **Predição de surtos de doenças infecciosas:** IA previu em Dezembro de 2019 o novo surto de corona vírus e onde ele apareceria em seguida.
- **Ajuda no diagnóstico de doenças:** IA tem sido usada para ajudar médicos a diagnosticarem o novo coronavírus através de imagens de raio-X e tomografias.
- **Criação de vídeos/fotos falsas:** IA foi usada para criar um vídeo viral utilizando trecho de “A Usurpadora” para falsificar uma conversa entre Lula e Bolsonaro.
- **Criação de novos medicamentos:** IA foi utilizada para criar uma nova droga capaz de combater o transtorno obsessivo-compulsivo (TOC). Encurtou o tempo para encontrar um novo medicamento de 4 para menos de 1 ano.




Foco do Curso



- Como vimos, IA é um termo muito amplo, abrangendo várias sub-áreas ou objetivos, que é usado para designar máquinas capazes executar **tarefas** de forma inteligente.
- Como um curso abrangendo todas essas sub-áreas seria muito longo, o foco do nosso curso será no estudo dos principais algoritmos de **Aprendizado de Máquina**.
- **Por quê?**
 - ML oferece ferramentas importantes para a solução eficiente de vários problemas de telecomunicações (pós-graduação stricto sensu em telecomunicações) e outros.
 - **Exemplo: Controle e otimização de parâmetros de sistemas complexos:** o número de parâmetros que um sistema 5G (PHY, MAC, etc.) precisa controlar e otimizar é muito grande e crescerá mais com o 6G.
 - ☐ Imagine se você pudesse otimizar **globalmente** todos os parâmetros do sistema apenas utilizando dados reais coletados da rede?
 - ☐ Mais ainda, imagine se você pudesse treinar um modelo que **aprendesse** um sistema de transmissão e recepção ótimo para um dado canal?
 - **Redução de complexidade/custo:** vários algoritmos de telecomunicações que apresentam desempenho ótimo não são utilizados na prática pois possuem complexidade computacional e/ou custos proibitivos.
 - **Oportunidades:** Pesquisas sobre a aplicação de aprendizado de máquina a problemas de telecomunicações ainda estão em fase de exploração. Além de muitos empregos na área de análise de dados.

Mas então, o que é ML?



- É uma sub-área ou objetivo da inteligência artificial.
- O termo foi cunhado em 1959, por Arthur Samuel, que o definiu como o “*campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados*”.
- Uma outra definição interessante feita por Jojo John Moolayil é “*Aprendizado de máquina é o processo de **induzir** inteligência em uma máquina sem que ela seja explicitamente programada*”.
 - **Indução**: aprender um modelo ou padrão geral a partir de exemplos.
- Algoritmos de ML são **orientados a dados**, ou seja, eles aprendem automaticamente um modelo/padrão geral (i.e., generalizar) a partir de grandes volumes de dados (i.e., exemplos).
- **Exemplo**: filtro de spam do Gmail.

Por que ML se tornou tão difundido?

Alguns dos principais motivos são:

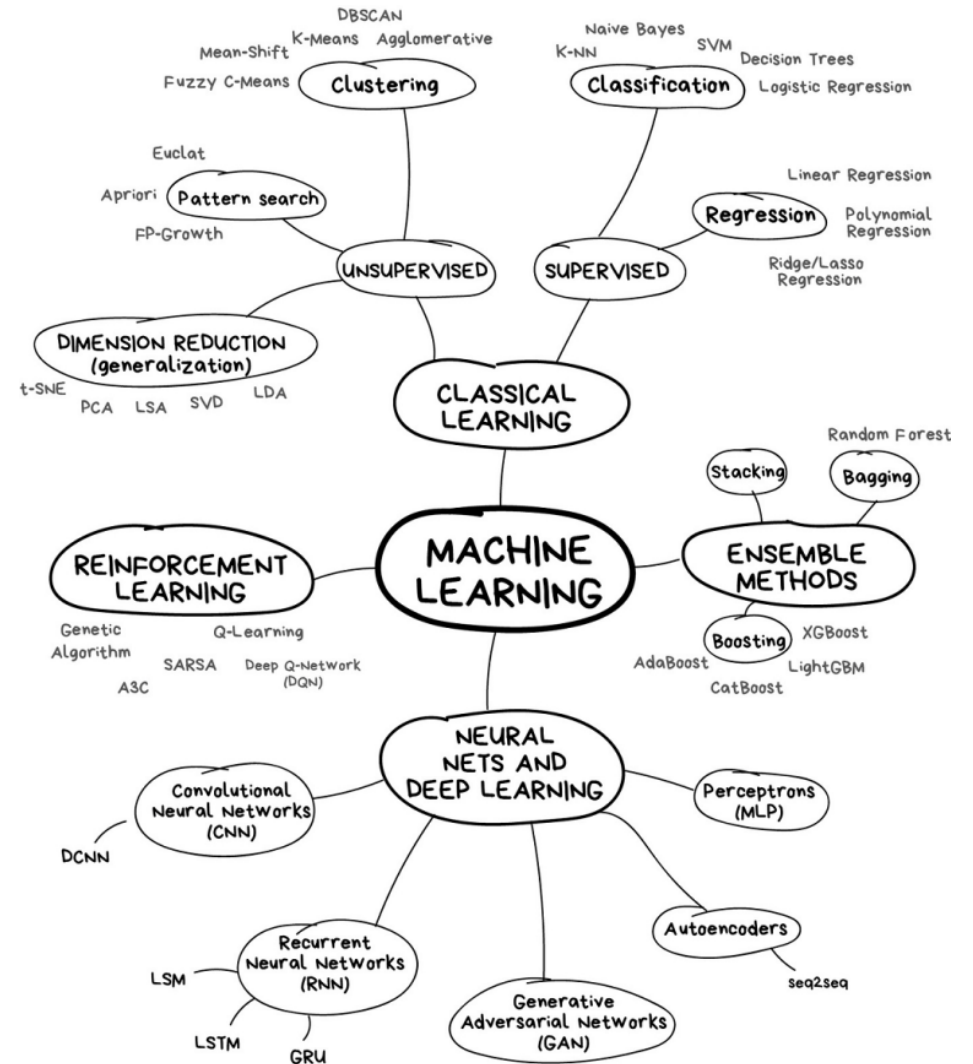
- Vivemos na era da informação. Nessa era, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos.
- Porém, para modelos de ML isso não é um problema e sim uma solução, pois quanto mais dados melhor será o aprendizado.
- Hoje em dia, dados são preciosíssimos e a extração de novas informações (úteis) vale ouro.
- O surgimento de recursos computacionais poderosos tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de novas e eficientes estratégias/técnicas de treinamento (i.e., aprendizagem), e.g., deep-learning, reinforment-learning, etc.
- Existência de frameworks e bibliotecas poderosas que facilitam o desenvolvimento de soluções com ML.



Tipos de Aprendizado de Máquina




- Os algoritmos de aprendizado de máquina podem ser agrupados nas seguintes categorias:

- Supervisionado
- Não-Supervisionado
- Semi-Supervisionado
- Por Reforço
- Metaheurístico



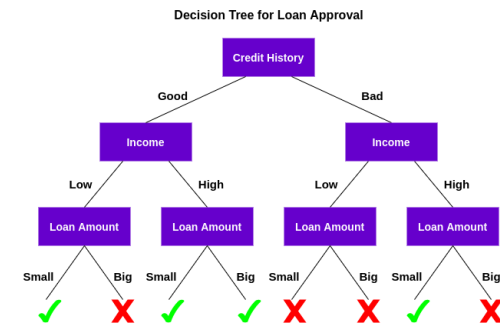

Aprendizado Supervisionado

- No aprendizado supervisionado a máquina sabe o que aprender, ou seja, além das entradas ela tem acesso às respostas esperadas.
- Neste tipo de aprendizado, os dados ou exemplos de treinamento incluem os **atributos**, x , que são a entrada do algoritmo de ML e as **soluções desejadas**, y , (i.e., as respostas corretas), chamadas de **rótulos** (ou *labels*, do Inglês).
- **Tarefa:** os modelos supervisionados de ML devem **aprender** uma **função** que mapeie as entradas x nas saídas y , ou seja, $y = f(x)$.
- Esse tipo de aprendizado pode ser dividido em problemas de **Regressão** e **Classificação**.
 - **Regressão:** o rótulo, y , pertence a um **conjunto infinito** de valores, i.e., números reais.
 - **Classificação:** o rótulo, y , pertence a um **conjunto finito** de valores, i.e., conjunto finito de classes.


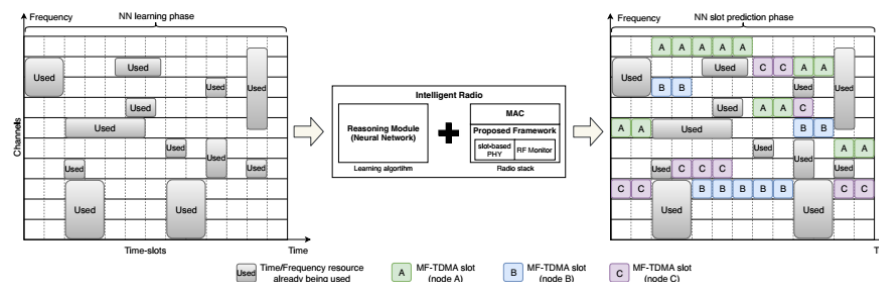



Principais Algoritmos para Aprendizado Supervisionado


- Regressão Linear.
- Regressão Logística.
- k vizinhos mais próximos (*k-nearest neighbors* - k -NN).
- Árvores de Decisão (*Decision Trees*).
- Florestas Aleatórias (*Random Forests*).
- Máquinas de Vetores de Suporte (*Support Vector Machines* - SVMs).
- Redes Neurais Artificiais
 - Alguns tipos podem ser não-supervisionados, e.g., auto-codificadores. Outros tipos podem ser semi-supervisionados, como as redes de crenças profundas (do Inglês, Deep Belief Networks).



Exemplos: predição de perda por caminho e da ocupação do espectro.




Aprendizado Não-Supervisionado



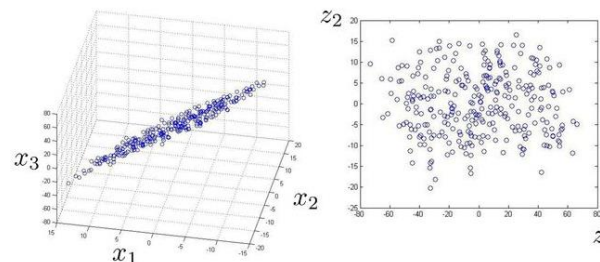
- Neste tipo de aprendizado, as máquinas não são informadas sobre o que aprender. Elas só recebem os exemplos de treinamento, x .
- Neste caso, os algoritmos ***aprendem/descobrem padrões*** (muitas vezes ocultos) presentes nos dados de entrada sem a presença de rótulos.
- **Tarefa:** os modelos devem ***aprender/descobrir*** padrões desconhecidos se baseando apenas nos exemplos de entrada.
- Trata problemas de clusterização, redução de dimensionalidade, detecção de anomalias (*outliers*) e aprendizado de regras de associação.

Clusterização




Redução de dimensionalidade


Reduce data from 3D to 2D



Detecção de Anomalias



Regras de associação






Of transactions that included milk:

- 71% included bread
- 43% included eggs
- 29% included toilet paper



Principais Algoritmos para Aprendizado Não-Supervisionado

- k-médias (*k-means*).
 - Particiona os atributos em k clusters (ou grupos) distintos com base na distância ao centroide de um cluster.
- Redes Neurais Artificiais, e.g., auto-encoders.
 - Os autoencoders são usados para redução ou aumento de dimensionalidade.
- Análise de Componentes Principais (*Principal Component Analysis - PCA*).
 - Redução de dimensionalidade.




Principais Algoritmos para Aprendizado Não-Supervisionado (continuação)

- Análise de Componentes Independentes (*Independent Component Analysis* - ICA)
 - Realiza uma espécie de clusterização baseada em propriedades estatísticas dos sinais envolvidos, por exemplo, a independência dos sinais de voz em um coquetel.
- Mapas Auto-Organizáveis (*Self-Organized Maps* - SOMs)
 - Tipo de rede neural usada para aprender a topologia e distribuição dos dados.
- Modelos Ocultos de Markov (*Hidden Markov Models* - HMM)
 - Usa os dados observados para recuperar uma sequência de estados.



Aprendizado Semi-Supervisionado

- Neste tipo de aprendizado, as máquinas tem acesso a exemplos com e sem rótulos.
- Geralmente envolve uma pequena quantidade de dados rotulados e uma grande quantidade de dados não-rotulados.
- É de grande ajuda em casos onde se ter uma grande quantidade de dados rotulados é muito caro ou complexo.
- Algoritmos de aprendizagem semi-supervisionada são o resultado da combinação de algoritmos supervisionados e não-supervisionados.
- **Exemplo:** Facebook e Instagram recebem várias fotos suas e de conhecidos e familiares seus. Em várias fotos postadas, um algoritmo de **clusterização** agrupa pessoas A, B e C, em outras várias fotos enviadas, pessoas B, D e E. Em um determinado momento, você carrega uma foto onde você fornece o nome (i.e., o label) de algumas dessas pessoas.




Aprendizado Por Reforço



- Abordagem totalmente diferente das anteriores pois não se tem exemplos de treinamento, sejam eles rotulados ou não.
- O algoritmo de aprendizagem por reforço, chamado de **agente** nesse contexto, deve aprender como se comportar em um **ambiente** através de interações do tipo “tentativa e erro”.
- O **agente** observa o **estado** do **ambiente** em que está inserido, seleciona e executa **ações** e recebe uma **recompensa** (ou **reforço**) em consequência das **ações** tomadas.
- Seguindo estes passos, o agente deve aprender por si só qual a melhor **estratégia**, chamada de **política**, para obter a maior recompensa possível ao longo do tempo.
- Uma **política** define qual **ação** o **agente** deve escolher quando estiver em uma determinada situação, ou seja, o **estado** do **ambiente**.
- Uma **política**, denotada pela letra Grega π , é uma função que mapeia os **estados** do **ambiente** em **ações** que o **agente** deve tomar, $\pi(s) = a$.

Principais Algoritmos de Aprendizado Por Reforço

- Q-Learning
 - Usado para encontrar uma **política** ótima de seleção de **ações** usando a **função-Q**.
 - **Q** ou **valor-Q**, representa a **qualidade** de uma dada **ação** em um determinado **estado**.
- Deep Q-Learning
 - Junção de Deep Learning + Q-Learning. Redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas com número gigantesco de **estados** e **ações**.
 - O Q-Learning tabela a **função-Q**, já o Deep Q-Learning encontra uma **função** que aproxime a **função-Q**.



Aprendizado Metaheurístico

- Uma **metaheurística** é um método **heurístico** usado para resolver de forma genérica problemas de otimização.
- **Heurística** é um método ou processo criado com o objetivo de encontrar soluções, de forma rápida e muitas vezes sub-ótimas, para um problema.
- **Metaheurísticas** são geralmente aplicadas a problemas para os quais não se conhece um algoritmo eficiente (problemas NP-completos).
- As metaheurísticas:
 - não garantem que uma solução globalmente ótima seja encontrada, mas podem encontrar uma solução suficientemente boa.
 - são estratégias que orientam o processo de busca.
 - não são específicas do problema, ou seja, são genéricas.
 - funcionam bem mesmo com capacidade de computação limitada.

Principais Algoritmos de Aprendizado Metaheurístico

- Algoritmo Genético (*Genetic Algorithm* - GA).
 - Inspirados pelo processo de seleção natural.
- Otimização por enxame de partículas (*Particle Swarm Optimization* - PSO).
 - Inspirado no comportamento de cardumes de peixes e de bandos de pássaros
- Otimização da colônia de formigas (*Ant Colony Optimization* - ACO).
 - Inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida.



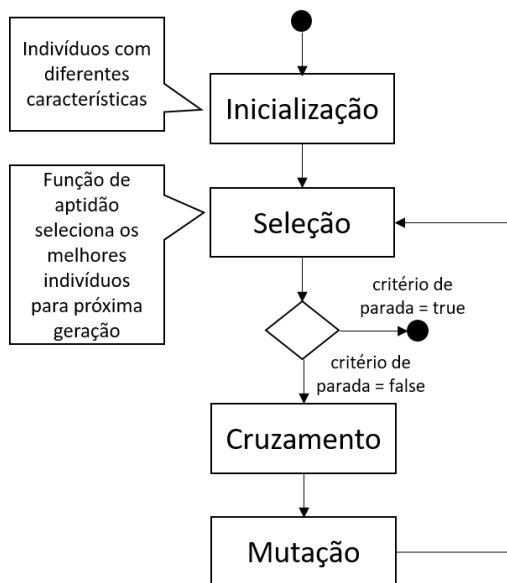


Figure 2. A. Ants in a pheromone trail between nest and food; B. an obstacle interrupts the trail; C. ants find two paths to go around the obstacle; D. a new pheromone trail is formed along the shorter path.

Tipos de Treinamento

Uma outra forma de se classificar algoritmos de ML é com relação se eles podem ser treinados incrementalmente ou não. Assim, os algoritmos podem ser divididos em algoritmos com treinamento:

- **incremental (online).**
- **em batelada (batch).**

Treinamento incremental

- Neste tipo de treinamento, o algoritmo aprende incrementalmente: exemplos de treinamento são apresentados sequencialmente um-a-um ou em pequenos grupos chamados de mini-batches (ou mini-lotes).
- Cada iteração de treinamento é rápida possibilitando que o sistema aprenda sobre novos dados à medida que eles chegam.
- Ótima opção para casos onde os dados chegam como um fluxo contínuo ou se tem recursos computacionais limitados.
- Entretanto, como não há pré-processamento/análise, dados corrompidos ou com problemas afetam a performance do sistema.

Treinamento em batelada

- Neste tipo de treinamento, o algoritmo é treinado com todos os exemplos disponíveis.
- É um tipo de treinamento simples, de fácil implementação e obtém ótimos resultados.
- Dados podem ser pré-processados/analísados, evitando assim, dados corrompidos ou com problemas.
- O treinamento é demorado e utiliza muitos recursos computacionais (e.g., CPU, memória) quando comparado ao treinamento incremental.
- Para treinar com novos exemplos é necessário iniciar o treinamento do zero.
- Se a quantidade de dados do conjunto de treinamento for muito grande pode ser impossível treinar em batelada.


Python, Jupyter & Colab



colab

O que é Python?



- Linguagem de programação de alto nível, interpretada, multiparadigma e gratuita.
- Foi lançada por Guido van Rossum em 1991.
- Possui um modelo de desenvolvimento comunitário, aberto e gerenciado pela *Python Software Foundation* (PSF).
- **Curiosidade:** o nome Python é uma homenagem ao grupo de humor britânico, Monty Python.



Por que Python?

Algumas razões são:

1. É uma das linguagens mais fáceis de se aprender.
2. É muito popular e será mais ainda nos próximos anos.
3. Grandes empresas a utilizam.
4. É a linguagem mais usada em aplicações de ML.
5. Possui vasto suporte on-line: tutoriais, vídeos, StackOverflow, etc.
6. É usada como linguagem educativa para ensino de computação e eletrônica (e.g., Raspberry Pi, LEGO Mindstormstem podem ter suas aplicações desenvolvidas em Python).
7. Possui um rico ecossistema de bibliotecas: SciPy, NumPy, Pandas, Matplotlib, SciKit-Learn, TensorFlow, OpenCV, etc.
8. Teve uma rápida adoção pela comunidade científica.
 - Bibliotecas disponíveis para áreas de engenharia, química, física, biologia, etc.
9. É gratuita e open-source.



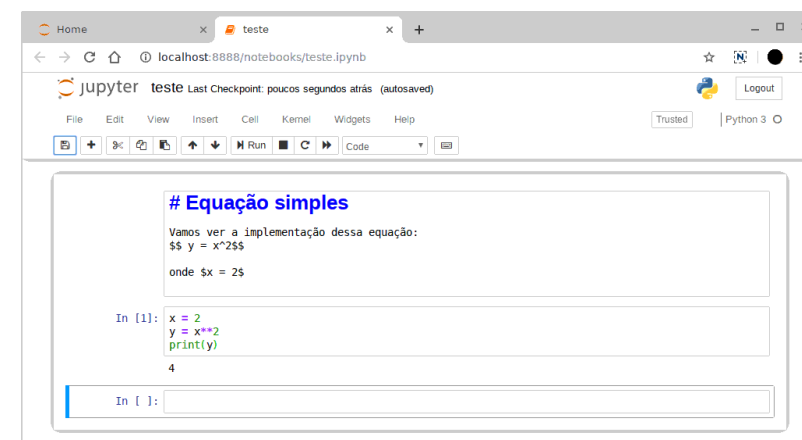
Executando códigos Python na nuvem

- Durante o curso, utilizaremos ambientes computacionais interativos baseados em **aplicações web** para criação de documentos virtuais, chamados de **notebooks**, os quais utilizaremos para execução de exemplos e exercícios.
- Os **notebooks** são documentos usados para criar e compartilhar código interativo juntamente com equações, gráficos e texto.
- Dessa forma, um **notebook** permite uma maneira interativa de programar e documentar o código.
- Existem vários ambientes computacionais interativos gratuitos disponíveis, mas usaremos o **Jupyter** ou o **Google Colaboratory**, que são os mais conhecidos e estáveis.

Jupyter



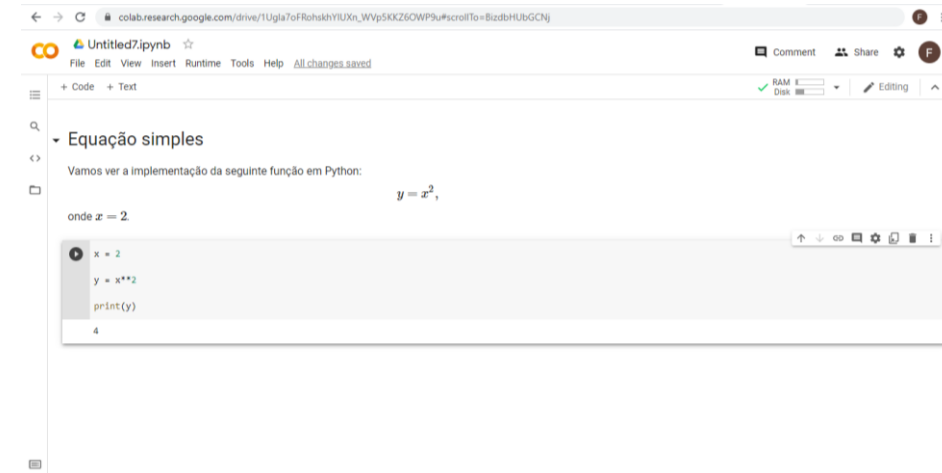
- **Jupyter**: aplicação web gratuita que permite a criação e edição de **notebooks** em navegadores web.
- Suporta a execução de várias linguagens de programação: Python, C++, C#, PHP, Julia, R, etc.
- Site oficial: <https://jupyter.org/>
- Algumas desvantagens do **Jupyter** são:
 - Poucos servidores disponíveis.
 - Depois de algum tempo inativo, a máquina virtual executando seu **notebook** se desconecta e você pode perder seu código.
- A Lista #0 contém um link para um tutorial de instalação do Jupyter.



Google Colaboratory (Colab)



- **Colab**: outra aplicação web gratuita, baseada no Jupyter, que permite a criação e edição de **notebooks** em navegadores web.
- É um produto da Google.
- Por hora, suporta apenas a execução de códigos em Python.
- Vantagens sobre o Jupyter:
 - Maior número de servidores.
 - Inicialização e processamento do código mais rápidos.
 - Fornece GPUs e TPUs gratuitamente.
 - Compartilhamento de notebooks entre usuários é mais fácil.
 - Salva os notebooks no seu Google Drive, evitando que você perca seu código.
- Site oficial: <https://colab.research.google.com/>



Alguns Exemplos

Histogramas

```
import numpy as np
import matplotlib.pyplot as plt


%matplotlib inline

data = np.random.randn(1000000)

# histograma (pdf)
plt.subplot(1, 2, 1)
plt.title('PDF')
plt.hist(data, bins=100, normed=True, color='b')

# CDF empirica
plt.subplot(1, 2, 2)
plt.title('CDF')
plt.hist(data, bins=100, normed=True, color='g', cumulative=True)

plt.savefig('histogram.png') # salva figura em arquivo
```




Figuras 3D

```
import matplotlib.pyplot as plt
# facilita visualizacao de figuras 3D
from mpl_toolkits.mplot3d import axes3d # graficos 3D sao habilitados importando axes3d

# para figuras interativas usar "notebook" ao inves de "inline"
%matplotlib notebook

ax = plt.subplot(111, projection='3d')
X, Y, Z = axes3d.get_test_data(0.1)
ax.plot_wireframe(X, Y, Z)

# salva figura em arquivo
plt.savefig('figura3d.png')
```



Ajuste de Curvas com Redes Neurais

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPRegressor # importa classe MLPRegressor do modulo neural network

%matplotlib inline

x = np.arange(-10, 10, 0.1)

# dados originais
y = 12 + 3 * np.exp(-0.05*x) + 1.4 * np.sin(1.2*x) + 2.1 * np.sin(-2.2*x + 3)


# faz com que o gerador de numeros aleatorios sempre forneça os mesmos valores
np.random.seed(42)

# adicionando ruído aos dados originais
y_noise = y + np.random.normal(0, 0.5, size = len(y))

# trata o ajuste de curva como um problema de regressao e treina um modelo para que se ajuste aos dados.
mlp = MLPRegressor(hidden_layer_sizes=(30,20,10), max_iter=10000, solver='lbfgs', alpha=0.9, activation='tanh')
yfit = mlp.fit(x[:, None], y_noise).predict(x[:, None])

plt.figure(figsize = (10,8))
plt.plot(x, y_noise, 'o', label = 'dados original + ruido')
plt.plot(x, y, 'k', label = 'dados original')
plt.plot(x, yfit, '-r', label = 'curva ajustada com MLP', zorder = 10)
plt.legend()
plt.xlabel('X')
plt.ylabel('y')

# salva figura em arquivo
plt.savefig(mlp_regression.png)
```



Referências


- [1] Athanasios Papoulis and S. Pillai, “Probability - Random Variables and Stochastic Processes,” McGraw Hill Education; 4th ed., 2017.
- [2] Stuart Russell and Peter Norvig, “Artificial Intelligence: A Modern Approach,” Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [3] Aurélien Géron, “Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”, 1st ed., O'Reilly Media, 2017.
- [4] Joseph Misiti, “Awesome Machine-Learning,” on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [5] Andriy Burkov, “The Hundred-Page Machine-Learning Book,” Andriy Burkov 2019.
- [6] C. M. Bishop, “Pattern Recognition and Machine Learning,” Springer, 1st ed., 2006.
- [7] S. Haykin, “Neural Networks and Learning Machines,” Prentice Hall, 3ª ed., 2008.
- [8] Coleção pessoal de livros,
https://drive.google.com/drive/folders/1lylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=s_haring

Avisos


- Lista #0, #1 e descrição do projeto prático já estão disponíveis no MS Teams.
- Todas as entregas devem ser feitas tanto no GitHub quanto no MS Teams.
 - Meu controle de entregas será via MS Teams e a validação será através do GitHub.
 - Se atentem às datas de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams.
- Horário de Atendimento
 - Todas as Quintas-Feiras das 13:30 às 15:30 via MS Teams.

Perguntas?



Obrigado!



Dilbert.com DilbertCartoonist@gmail.com



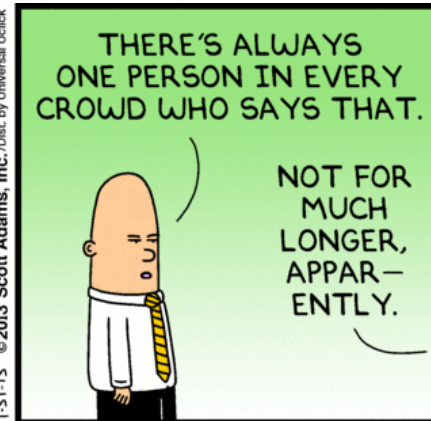
2-2-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



Dilbert.com DilbertCartoonist@gmail.com



1-31-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



www.dilbert.com scottadams@aol.com



©2003 United Feature Syndicate, Inc.



