

TP555 - Inteligência Artificial e Machine Learning: *Introdução*




Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br


Objetivos do Curso

- Apresentar os **principais algoritmos de aprendizado de máquina** ou do inglês, machine learning (ML).
- Portanto, o foco principal do curso é em ***Machine Learning***, o qual dará a vocês um conjunto de ferramentas úteis para suas pesquisas.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir sobre os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Aplicar algoritmos de ML para a resolução de problemas.
 - Analisar e entender novos algoritmos de ML.
 - Compreender artigos científicos que utilizam ML.
 - Realizar pesquisa que envolva ML e discutir os resultados obtidos.



Avaliação do Curso

- 2 Provas
 - Cada prova valerá 35% da nota (datas ainda serão definidas).
- Listas de Exercícios
 - 10% da nota.
 - Listas serão disponibilizadas ao final de cada tópico.
 - [Devem ser comitadas no GitHub e entregues no MS Teams.](#)
- Projeto Prático
 - 20% da nota.
 - Tema será escolhido por vocês.
 - [Link para o documento do projeto.](#)





Motivação

- **Pesquisa:** algoritmos de ML tem um grande potencial para solucionar problemas em várias áreas tais como a de jogos, transportes, segurança, saúde, tecnologia, varejo, finanças, etc. Portanto, o emprego de ML em problemas destas áreas pode gerar pesquisas inovadoras.
 - Já se prevê que ML terá um papel importante no desenvolvimento da próxima geração de redes móveis e sem-fio (e.g., 6G).
- **Emprego:** grandes companhias (e.g., Google, Facebook, Amazon, etc.) usam ML para resolver os mais diversos tipos de problemas e assim aumentarem sua eficiência/lucros.







Um Pouco de História

- A ideia de criar uma máquina pensante ou uma criatura artificial que imitasse as habilidades humanas é muito antiga, remontando à Grécia antiga.
- **Mitologia grega:** Talos, um autômato (máquina que realiza ações que lembram humanos ou animais) criado para proteger a princesa Europa de Creta de invasores.
- **300 A.C.:** Aristóteles almejava substituir a mão-de-obra escrava por objetos autônomos.
- **1642:** Pascal constrói a primeira calculadora mecânica do mundo, a *La pascaline*.
- **1822:** Charles Babbage cria os primeiros computadores mecânicos, as *máquinas diferencial* e *analítica*, se tornando o “pai dos computadores”.
- **1837:** Ada Lovelace escreve o primeiro programa de computador para a *máquina analítica* de Babbage, se tornando a primeira “programadora” conhecida.



Um Pouco de História (continuação)


- **1847:** George Boole cria a lógica booleana, lançando as bases para a era da informação.
- **1943:** Alan Turing e um grupo de codebreakers constroem Colossus, o primeiro computador programável, digital e eletrônico do mundo.
- **1945:** ENIAC, o primeiro computador de uso-geral é construído.
- **1943:** McCulloch e Pitts propõem um modelo matemático para o funcionamento de um neurônio. Lançando as bases para a criação das redes neurais artificiais.
- **1950:** Alan Turing cria o “*teste de Turing*”, que testa a capacidade de uma máquina em exibir comportamento inteligente indistinguível ao de um ser humano.
- **1952:** Arthur Samuel cria o primeiro programa de auto-aprendizagem (*aprendizado de máquina*) do mundo, o *Checkers-Player*, sendo a primeira demonstração do conceito de inteligência artificial.
- **1956:** Surgimento da área de pesquisa em IA em um workshop no Dartmouth College nos EUA onde o termo IA foi cunhado por John McCarthy.



Um Pouco de História (continuação)

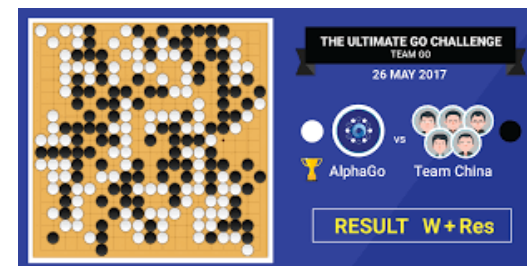



- **1957:** Newell e Simon criam o *Solucionador de Problemas Gerais*, um programa para resolução de problemas (e.g., provas de teoremas, problemas de geometria, jogo de xadrez, etc.)
- **1958:** John McCarthy cria a linguagem *Lisp*, que foi a linguagem para desenvolvimento de IA dominante até os anos 90.
- **1958:** Frank Rosenblatt cria a primeira rede neural artificial, chamada de *Perceptron*.
- **1959:** Arthur Samuel cunha o termo *Aprendizado de Máquina* enquanto trabalhava na IBM.
- **1970-1980:** Devido a limitação dos computadores da época, IA atravessou alguns **invernos**, i.e., interesse e financiamentos na área diminuíram drasticamente.
- **1986:** Ascensão do aprendizado de máquina: redes neurais retornam a popularidade e grandes avanços em algoritmos e aplicações de ML.



Um Pouco de História (continuação)

- **1997:** O supercomputador da IBM, chamado de *DeepBlue*, vence o campeão mundial de xadrez, Garry Kasparov.
- **2002:** O primeiro aspirador de pó robótico, chamado de *Roomba*, é lançado pela *iRobot*.
- **2009:** O Google constrói o primeiro carro autônomo que dirige em áreas urbanas.
- **2011:** Outro supercomputador da IBM, chamado *Watson*, vence o show de perguntas e respostas *Jeopardy!*.
- **2011-2014:** Surgem assistentes pessoais, tais como *Siri*, *Google Now*, *Alexa* e *Cortana*, que utilizam reconhecimento de fala para responder questões e realizar tarefas simples.
- **2016:** O programa conhecido como *AlphaGo*, da empresa *DeepMind*, derrota o então 18 vezes campeão mundial de *Go*, Lee Sedol.
- **2018:** Universidades de todo o mundo começam a oferecer cursos de AI e ML.



Inatel

Inteligência + Artificial (IA)



- Vocês já refletiram sobre a definição destas duas palavras?
- **Inteligência:** são as **habilidades mentais** de **conhecer, compreender, aprender, resolver problemas e adaptar-se**.
 - **Latim** -> prefixo *inter*: “entre” + sufixo *legere*: “escolha” => entre escolhas.
 - **Capacidade de escolha** de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- **Artificial:** produzido pela mão do homem, não pela natureza, geralmente como uma cópia de algo natural.

Habilidades mentais desenvolvidas de forma não natural pela mão do homem.

Cópias de habilidades mentais humanas criadas de forma não natural pelo homem.

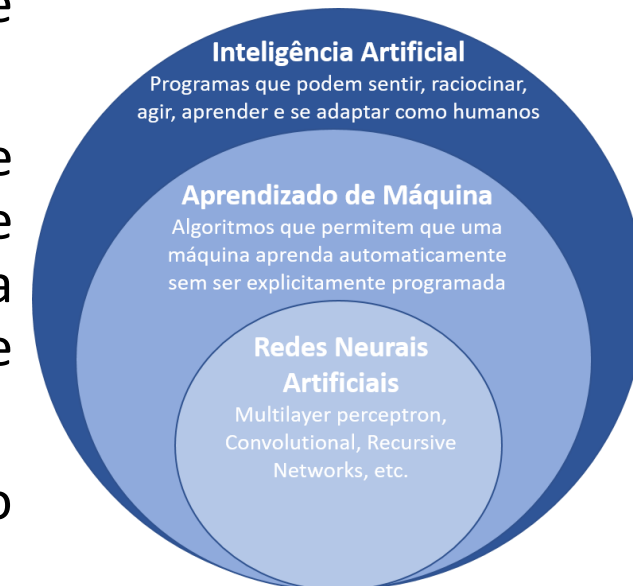


Definições e Objetivo da IA

- **Definição:** “Capacidade de um sistema de interpretar corretamente dados externos (vindos do ambiente), aprender com esses dados e usá-los para atingir objetivos específicos por meio de adaptação flexível.” (Andreas Kaplan).
- **Definição:** “Ciência e engenharia de produzir máquinas inteligentes.” (John McCarthy).
- **Objetivo:** Criar máquinas que *imitem* nossa capacidade mental para uma determinada tarefa.
- Essa *imitação* é apenas uma aproximação pois ainda não conseguimos criar matéria viva.
- É por isso que em IA fala-se da criação de máquinas que são *modelos aproximados* de nossa capacidade de aprender, raciocinar, enxergar, falar, ouvir, etc.

Inteligência Artificial


- IA é uma área muito ampla que **engloba** várias aplicações (ou subáreas ou ainda objetivos) tais como (i) *processamento de linguagem natural*, (ii) *representação do conhecimento*, (iii) *raciocínio automatizado*, (iv) *visão computacional*, (v) *robótica*, e (vi) *aprendizado de máquina* que por sua vez engloba redes neurais artificiais, etc.
- **Aprendizado** é apenas um dos aspectos da inteligência humana (outros são: lógica, abstração, memorização, planejamento, resolução de problemas, etc.)
- **Exemplo:** Um problema matemático pode ser solucionado (i) caso ele tenha sido resolvido antes e sua solução **aprendida** ou (ii) caso ele nunca tenha sido visto antes mas um indivíduo com inteligência imagina/pensa possíveis maneiras de como resolve-lo baseado no que ele **sabe (conhecimento)**.
- IA utiliza a **experiência** para adquirir **conhecimento** e também como aplicar esse conhecimento a problemas desconhecidos.



Algumas Aplicações de IA

Algumas áreas onde IA é aplicada são:

- **Transporte:** veículos terrestres e aéreos autônomos, previsão do tráfego, etc.
- **Negócios:** recomendação de anúncios/produtos, chatbots para atendimento ao cliente, etc.
- **Educação:** pontuação automatizada de fala em testes de Inglês, correção de provas, chatbots para realização de matrículas, dúvidas, etc.
- **Clima:** previsão do tempo (temperatura, chuva, furacões, etc.).
- **Medicina:** detecção e/ou previsão de doenças (câncer, Alzheimer, Pneumonia, COVID-19, etc.), chatbots que auxiliam no agendamento de consultas e respondendo perguntas referentes a uma doença, descoberta de novas drogas, etc.
- **Finanças:** detecção de fraudes com cartão de crédito, previsão do comportamento do mercado de ações, etc.
- **Tecnologia:** filtros AntiSpam, “motores” de busca como o do Google, reconhecimento de fala, conversão de texto/fala e fala/texto, assistentes pessoais on-line (e.g., *Siri*, *Alexa*, etc.).



Algumas Aplicações em Comunicações Digitais




- **Estimação de canal e detecção de sinais**
 - Ex.: IA estima o canal e detecta o símbolo transmitido conjuntamente, sem a necessidade de estimar o canal primeiro e depois detectar o símbolo transmitido.
- **Aprendizado de Sistemas de Comunicação de Ponta-a-Ponta**
 - Ex.: IA otimiza conjuntamente os blocos de processamento do Tx e Rx (estimação de canal, equalização, codificação/decodificação de canal, modulação/demodulação, etc.)
- **Comunicações em Ondas Milimétricas**
 - Ex.: IA é utilizada para prever bloqueios e realizar handovers proativos.
- **Alocação de Recursos**
 - Ex.: IA é empregada em redes IoT de baixa potência para entender o comportamento de dispositivos vizinhos e assim realizar a alocação de recursos com o intuito de evitar colisões, aumentando a vida útil das baterias e a taxa de dados úteis (goodput).
- **Rádio-sobre-Fibra**
 - Ex.: IA é utilizada para equalizar e detectar conjuntamente sinais transmitidos através de canais sem-fio e óticos, considerando conjuntamente os efeitos de ambos os canais.
- **Pré-distorção**
 - Ex.: IA é utilizada para aproximar uma equação que aumente a região linear de um amplificador de potência.
- **E vários outros tópicos.**





Exemplos interessantes de uso da IA

- **Predição de surtos de doenças infecciosas:** IA previu em Dezembro de 2019 o novo surto de corona vírus e onde ele apareceria em seguida.
- **Ajuda no diagnóstico de doenças:** IA tem sido usada para ajudar médicos a diagnosticarem o novo coronavírus através de imagens de raio-X e tomografias.
- **Criação de vídeos/fotos falsas:** IA foi usada para criar vídeo viral utilizando trecho de “A Usurpadora” para falsificar uma conversa entre Lula e Bolsonaro.
- **Criação de novos medicamentos:** IA foi utilizada para criar uma nova droga capaz de combater o transtorno obsessivo-compulsivo (TOC). Encurtou o tempo para encontrar novos medicamentos de 4 para menos de 1 ano.



Foco do Curso



- IA é um termo genérico (***guarda-chuva***) usado para designar máquinas capazes executar ***tarefas*** de forma inteligente.
- IA é dividida em vários objetivos ou sub-áreas, sendo as principais: ***planejamento, representação do conhecimento e raciocínio, aprendizado de máquina, processamento de linguagem natural, visão computacional, robótica e inteligência artificial geral.***
- **Foco do curso:** estudo dos principais algoritmos de ***Aprendizado de Máquina.*** **Por quê?**
 - ML oferece ferramentas importantes para a solução eficiente de vários problemas de telecomunicações (pós-graduação stricto sensu em telecomunicações).
 - ***Exemplo: Controle e otimização de parâmetros de sistemas complexos:*** o número de parâmetros que um sistema 5G (PHY, MAC, etc.) precisa controlar e otimizar é muito grande e crescerá mais com o 6G.
 - ☐ Imagine se você pudesse otimizar ***globalmente*** todos os parâmetros do sistema apenas utilizando dados reais coletados da rede?
 - ☐ Mais ainda, imagine se você pudesse treinar um modelo que ***aprendesse*** um sistema de transmissão e recepção ótimo para um dado canal?
 - ***Redução de complexidade/custo:*** vários algoritmos de comunicações que apresentam desempenho ótimo não são utilizados na prática pois possuem complexidade computacional e/ou custo proibitivos.
 - ***Oportunidades:*** Pesquisas sobre a aplicação de aprendizado de máquina a problemas de comunicação ainda estão em fase de exploração.



Natural Language
Processing



Knowledge
Representation

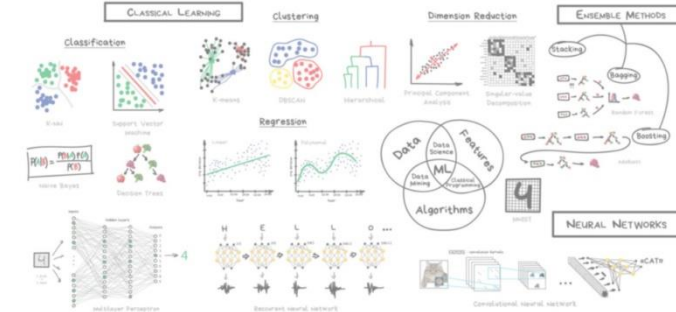


Automated
Reasoning



Machine
Learning

Mas então, o que é ML?



- É uma sub-área ou objetivo da inteligência artificial.
- O termo foi cunhado em 1959, por Arthur Samuel, que o definiu como o “campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados”.
- Uma outra definição interessante é “Aprendizado de máquina é o processo de **induzir** inteligência em uma máquina sem que ela seja explicitamente programada”, Jojo John Moolayil.
- **Indução**: aprender um modelo ou padrão geral a partir de exemplos.
- Algoritmos de ML são **orientados a dados**, ou seja, eles aprendem automaticamente um modelo/padrão geral (i.e., generalizar) a partir de grandes volumes de dados (i.e., exemplos).
- **Exemplo**: filtro de spam do Gmail.

Por que ML se tornou tão importante?

Alguns dos principais motivos são:

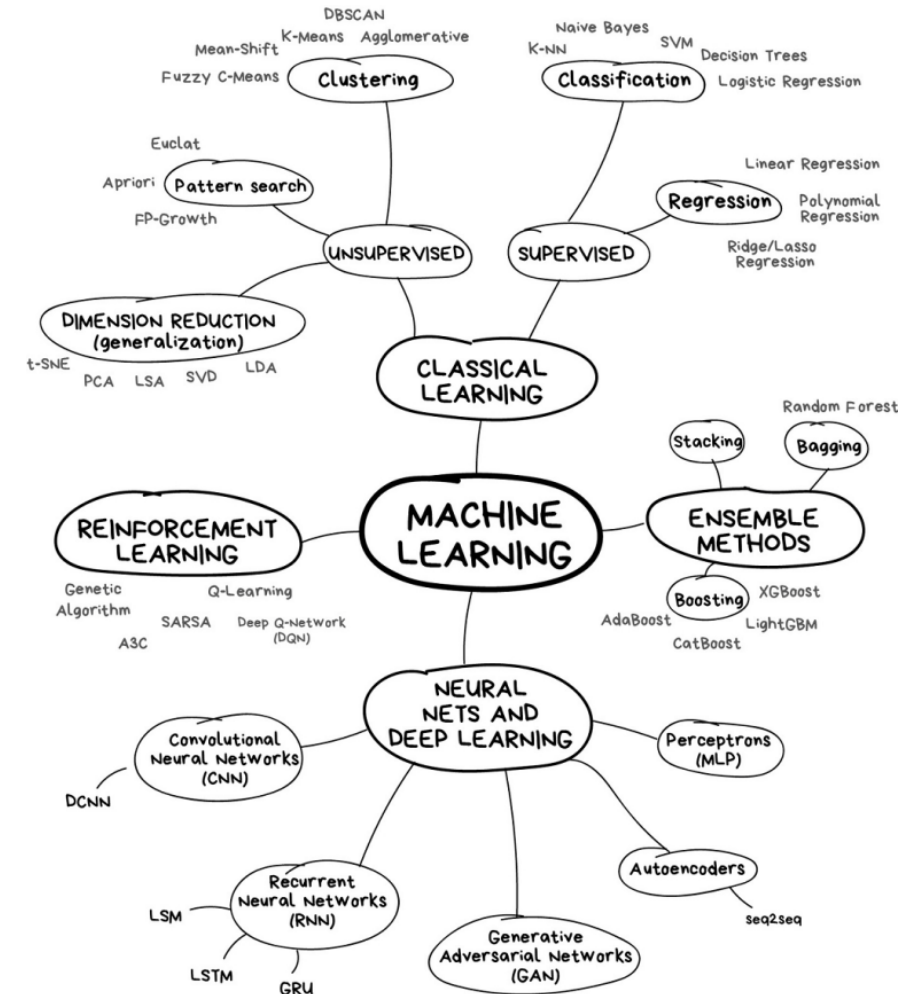
- Vivemos na era da informação. Nessa era, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos.
- Porém, para modelos de ML isso não é um problema e sim uma solução, quanto mais dados melhor será o aprendizado.
- Hoje em dia, dados são preciosíssimos e a extração de novas informações (úteis) vale ouro.
- O surgimento de recursos computacionais poderosos tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de novas e eficientes estratégias/técnicas de treinamento (i.e., aprendizagem).
- Existência de frameworks e bibliotecas poderosas que facilitam o desenvolvimento de soluções com ML.



Tipos de Aprendizado de Máquina




Os algoritmos de aprendizado de máquina podem ser agrupados da seguinte forma:

- Supervisionado
- Não-Supervisionado
- Semi-Supervisionado
- Por Reforço
- Evolutivo



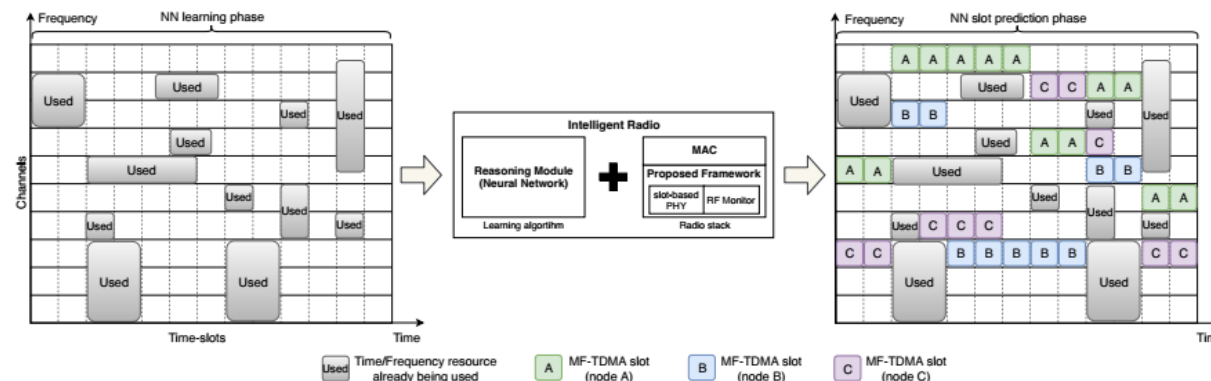

Aprendizado Supervisionado

- Os dados de treinamento, chamados de **atributos** ou exemplos de treinamento (ou também características, do Inglês, features) que alimentam o algoritmo de ML incluem as **soluções desejadas** (i.e., as respostas corretas), chamadas de **rótulos** (labels).
- **Resumindo:** Os modelos de ML **aprendem** uma função que mapeie as entradas nas saídas, $y = f(x)$.
- Esse tipo de aprendizado pode ser dividido em problemas de: **Regressão** e **Classificação**.
 - **Classificação:** Rótulo, y , pertence a um **conjunto finito** de valores, i.e., conjunto finito de classes.
 - **Regressão:** Rótulo, y , pertence a um **conjunto infinito** de valores, i.e., números reais.




Principais Algoritmos para Aprendizado Supervisionado

- Regressão Linear e logística.
- k vizinhos mais próximos, k-nearest neighbors (k-NN)
- Árvores de Decisão, do Inglês, Decision Trees
- Florestas Aleatórias, do Inglês, Random Forests
- Máquinas de Vetores de Suporte, do Inglês, Support Vector Machines (SVMs)
- Redes Neurais Artificiais
 - Alguns tipos podem ser não-supervisionados, e.g., auto-codificadores. Outros tipos podem ser semi-supervisionados, como as redes de crenças profundas (do Inglês, Deep Belief Networks).

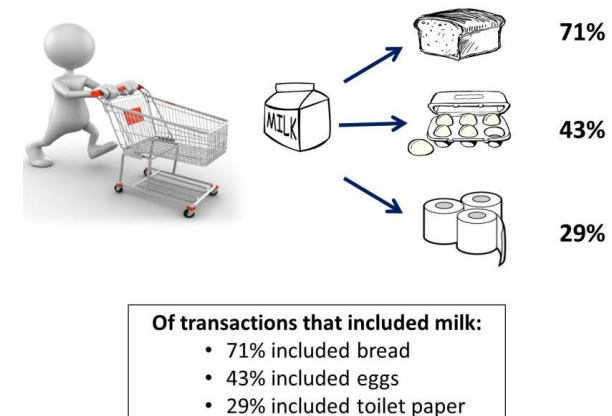

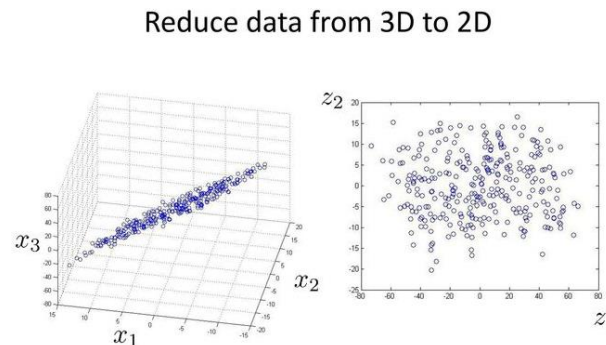



Exemplos: predição de perda por caminho e da ocupação do espectro.

Aprendizado Não-Supervisionado



- As máquinas não são informadas sobre o que aprender. Elas só recebem os exemplos de treinamento.
- Neste caso, os algoritmos ***aprendem/descobrem padrões*** (ocultos) presentes nos dados de entrada sem a presença de rótulos.
- **Resumindo:** Os modelos ***descobrem/aprendem*** padrões desconhecidos.
- Trata problemas de clusterização, redução/aumento de dimensionalidade, detecção de anomalias (outliers) e aprendizado de regras de associação.






Aprendizado Não-Supervisionado

- **Clusterização:** agrupa automaticamente os dados de entrada em classes. Pode-se dizer que a clusterização tem como objetivo fazer com que a máquina rotule os dados de entradas.
 - **Exemplo de aplicação:** Agrupar de clientes similares em termos de comportamento ou características para envio de propaganda personalizada.
- **Redução da dimensionalidade:** tem por objetivo encontrar representações com menor dimensão das features.
 - **Exemplo de aplicação:** Em reconhecimento de faces, as features possuem grandes dimensões o que dificulta o treinamento de algoritmos de ML, portanto, diminuindo-se a dimensão das features pode-se diminuir o tempo de treinamento sem afetar grandemente a performance do algoritmo utilizado.
- **Aumento da dimensionalidade:** encontrar representações das features que possuam uma dimensão maior, aumentando a quantidade de informação.
 - **Exemplo de aplicação:** Em sistemas de comunicação digital, o aumento de dimensionalidade é utilizado para encontrar mensagens que possuam informações adicionais (i.e., redundância), o que consequentemente aumenta a chances de decodificação da mensagem transmitida.
- **Detecção de Anomalias:** detecta se uma feature pertence à mesma distribuição que as features já conhecidas, com isso, identifica features que levantam suspeitas por serem significativamente diferentes das outras.
 - **Exemplo de aplicação:** detecção de fraude bancária, defeito estrutural, controle de qualidade em fábricas, etc.
- **Regras de associação:** associa as features, encontrando regras que descrevam grandes porções dos dados.
 - **Exemplo de aplicação:** Posicionamento de itens em supermercados. Por exemplo, encontrar uma regra de associação que diz que mais de 70% dos clientes que comprem leite também comprem pão e portanto, o supermercado pode colocar ambos produtos próximos uns dos outros, aumentando a chance da venda desses produtos.



Principais Algoritmos para Aprendizado Não-Supervisionado

- k-médias (k-means)
 - Particiona as features em k clusters distintos com base na distância ao centroide de um cluster.
- Redes Neurais Artificiais, e.g., auto-encoders
 - Os autoencoders são usados para redução ou aumento de dimensionalidade.
- Análise de Componentes Principais (Principal Component Analysis, PCA)
 - Redução de dimensionalidade.




Principais Algoritmos para Aprendizado Não-Supervisionado

- Análise de Componentes Independentes (Independent Component Analysis, ICA)
 - Realiza uma espécie de clusterização baseada em propriedades estatísticas dos sinais envolvidos.
- Mapas Auto-Organizáveis (Self-Organized Map, SOM)
 - Tipo de rede neural usada para aprender a topologia e distribuição dos dados.
- Modelos Ocultos de Markov (Hidden Markov Models, HMM)
 - usa dados observados para recuperar uma sequência de estados.





Aprendizado Semi-Supervisionado

- As máquinas tem acesso a exemplos com e sem rótulos.
- Geralmente envolve uma pequena quantidade de dados rotulados e uma grande quantidade de dados não-rotulados.
- É de grande ajuda em casos onde se ter uma grande quantidade de dados rotulados é muito caro ou complexo.
- Algoritmos de aprendizagem semi-supervisionada são o resultado da combinação de algoritmos supervisionados e não-supervisionados.
- **Exemplo:** Facebook e Instagram recebem várias fotos suas e de conhecidos seus. Em várias fotos enviadas a eles, um algoritmo de **clusterização** agrupa pessoas A, B e C, em outras várias fotos enviadas, pessoas B, D e E. Em um determinado momento, você carrega uma foto onde você fornece o nome (label) de algumas dessas pessoas.




Aprendizado Por Reforço

- Abordagem totalmente diferente das anteriores pois não se tem dados de treinamento, sejam eles rotulados ou não.
- O algoritmo de aprendizagem, chamado de **agente** nesse contexto, deve aprender como se comportar em um **ambiente** através de interações do tipo “tentativa e erro”.
- O **agente** observa o **estado** do **ambiente** em que está inserido, seleciona e executa **ações** e recebe uma **recompensa** (ou **reforço**) em consequência das **ações** tomadas.
- Seguindo estes passos, o agente deve aprender por si só qual a melhor **estratégia**, chamada de **política**, para obter a maior recompensa possível ao longo do tempo.
- Uma **política** define qual **ação** o **agente** deve escolher quando estive em uma determinada situação, ou seja, o **estado** do **ambiente**.
- Uma **Política**, denotada por π , é uma função que mapeia os **estados** do **ambiente** em **ações** que o **agente** deve tomar, $\pi(s) = a$.



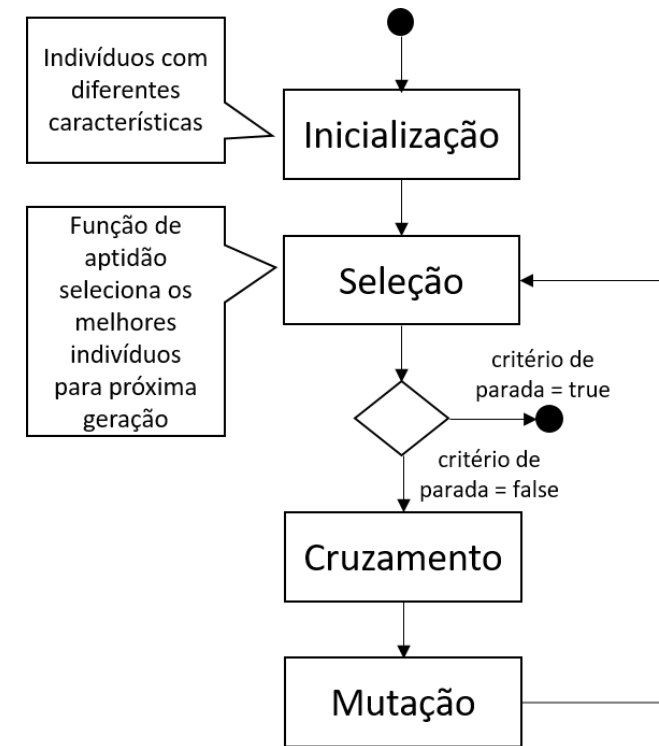
Principais Algoritmos de Aprendizado Por Reforço

- Q-Learning
 - Usado para encontrar uma **política** ótima de seleção de **ações** usando a **função-Q**.
 - 'Q', ou **valor-Q**, representa a **qualidade** de uma dada **ação** em um determinado **estado**.
- Deep Q-Learning
 - Junção de Deep Learning + Q-Learning. Redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas com número gigantesco de **estados** e **ações**.
 - O Q-Learning tabela a **função-Q**, já o Deep Q-Learning encontra uma função que aproxime a **função-Q**.



Aprendizado Evolutivo

- Aprendizado baseado na evolução biológica dos seres vivos.
- Novos **indivíduos** com diferentes **características**, pertencentes a uma **população**, são criados através de **cruzamentos** e **mutações** onde apenas os mais aptos são **selecionados** (**seleção natural**) e passam suas **características** para uma nova geração. Com isso a **população** se torna mais apta a cada geração.
- Utilizado para encontrar soluções de problemas de otimização.



Principais Algoritmos de Aprendizado Evolutivo

- Algoritmos Genéticos.
 - Inspirados pelo processo de seleção natural.
- Optimização por enxame de partículas (Particle Swarm Optimization, PSO).
 - Inspirado no comportamento de cardumes de peixes e de bandos de pássaros
- Optimização da colônia de formigas (Ant Colony Optimization, ACO).
 - Inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida.



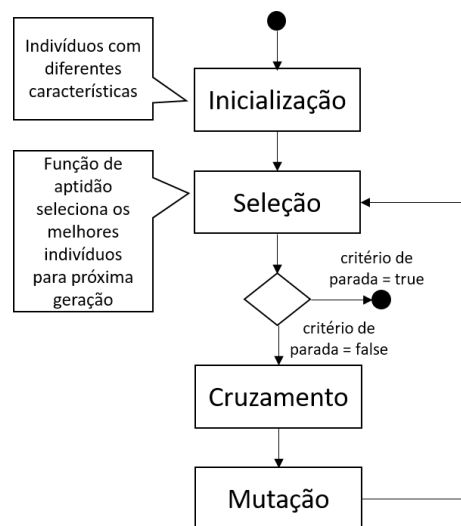


Figure 2. A. Ants in a pheromone trail between nest and food; B. an obstacle interrupts the trail; C. ants find two paths to go around the obstacle; D. a new pheromone trail is formed along the shorter path.

Tipos de Treinamento

Uma outra forma de classificar algoritmos de ML é se eles podem ser treinados incrementalmente ou não. Assim, os algoritmos são basicamente divididos em:

- **Treinamento em batelada (batch)**
- **Treinamento incremental (online)**

Treinamento em Batelada

- Algoritmo não pode ser treinado incrementalmente, sendo treinado com todos os exemplos (i.e., dados de treinamento) disponíveis.
- O treinamento é demorado e utiliza muitos recursos computacionais (e.g., CPU, memória, etc.).
- Para treinar com novos exemplos é necessário iniciar o treinamento do zero.
- Se a quantidade de dados do conjunto de treinamento for muito grande pode ser impossível treinar em batelada.
- Dados podem ser pré-processados/analísados, evitando assim, dados corrompidos ou com problemas.
- É um tipo de treinamento simples, de fácil implementação e obtém ótimos resultados.

Treinamento Incremental

- Algoritmo aprende incrementalmente: exemplos de treinamento são apresentados sequencialmente um-a-um ou em pequenos grupos chamados de mini-batches (ou mini-lotes).
- Cada iteração de treinamento é rápida possibilitando que o sistema aprenda sobre novos dados à medida que eles chegam.
- Ótima opção para casos onde os dados chegam como um fluxo contínuo ou se tem recursos computacionais limitados.
- Como não há pré-processamento/análise, dados corrompidos ou com problemas afetam a performance do sistema.


Python, Jupyter & Colab



colab

O que é Python?



- Linguagem de programação de alto nível, interpretada, de script, multiparadigma (suporta os paradigmas orientado a objetos, imperativo, funcional, procedural e reflexivo).
- Foi lançada por Guido van Rossum em 1991.
- Possui um modelo de desenvolvimento comunitário, aberto e gerenciado pela Python Software Foundation.
- **Curiosidade:** o nome Python é uma homenagem ao grupo de humor britânico, Monty Python.



Por que Python?


Algumas razões são:

1. É uma das linguagens mais fáceis de se aprender.
2. Python é muito popular e será mais ainda nos próximos anos.
3. Grandes empresas usam python.
4. Python é a linguagem mais usada em aplicações de Machine Learning.
5. Possui um vasto suporte on-line: Tutorials, Videos e StackOverflow.
6. Python é usada como linguagem educativa para ensino de computação e eletrônica (e.g., Raspberry Pi, LEGO Mindstormstem suas aplicações desenvolvidas em Python).
7. Python é gratuito e open-source.
8. Possui um rico ecossistema de bibliotecas: TensorFlow, OpenCV, Scrappy, Ipython, etc.



Programação Científica e Python

- Teve uma rápida adoção pela comunidade científica.
 - Engenharias
 - Biologia
 - Química
 - Física
 - Etc.



Jupyter

- **Jupyter**: aplicação web que permite criar e compartilhar documentos contendo código, equações, visualizações e texto explicativo.
- Suporta execução em dezenas de linguagens de programação: Python, C++, C#, PHP, Julia, R, etc.
- <https://jupyter.org/>
- A Lista #0 contém um link para um tutorial de instalação do Jupyter.
- Pode ser usado para execução de exemplos e exercícios do curso.



Google Colaboratory (Colab)



- **Colab:** outra aplicação web, baseada no Jupyter, que permite criar e compartilhar documentos contendo código, equações, visualizações e texto explicativo.
- É um produto da Google.
- Por hora, suporta apenas a execução de programas em Python.
- Vantagens sobre o Jupyter:
 - Maior número de servidores.
 - Fornece GPUs e TPUs gratuitamente.
 - Compartilhamento de notebooks entre usuários é mais fácil.
- <https://colab.research.google.com/>
- Pode também ser usado para execução de exemplos e exercícios do curso.

Alguns Exemplos

Histogramas

```
import numpy as np
import matplotlib.pyplot as plt


%matplotlib inline

data = np.random.randn(1000000)

# histograma (pdf)
plt.subplot(1, 2, 1)
plt.title('PDF')
plt.hist(data, bins=100, normed=True, color='b')

# CDF empirica
plt.subplot(1, 2, 2)
plt.title('CDF')
plt.hist(data, bins=100, normed=True, color='g', cumulative=True)

plt.savefig('histogram.png') # salva figura em arquivo
```




Figuras 3D

```
import matplotlib.pyplot as plt
# facilita visualizacao de figuras 3D
from mpl_toolkits.mplot3d import axes3d # graficos 3D sao habilitados importando axes3d

# para figuras interativas usar "notebook" ao inves de "inline"
%matplotlib notebook

ax = plt.subplot(111, projection='3d')
X, Y, Z = axes3d.get_test_data(0.1)
ax.plot_wireframe(X, Y, Z)

# salva figura em arquivo
plt.savefig('figura3d.png')
```



Ajuste de Curvas com Redes Neurais

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPRegressor # importa classe MLPRegressor do modulo neural network

%matplotlib inline

x = np.arange(-10, 10, 0.1)

# dados originais
y = 12 + 3 * np.exp(-0.05*x) + 1.4 * np.sin(1.2*x) + 2.1 * np.sin(-2.2*x + 3)


# faz com que o gerador de numeros aleatorios sempre forneça os mesmos valores
np.random.seed(42)

# adicionando ruido aos dados originais
y_noise = y + np.random.normal(0, 0.5, size = len(y))

# trata o ajuste de curva como um problema de regressao e treina um modelo para que se ajuste aos dados.
mlp = MLPRegressor(hidden_layer_sizes=(30,20,10), max_iter=10000, solver='lbfgs', alpha=0.9, activation='tanh')
yfit = mlp.fit(x[:, None], y_noise).predict(x[:, None])

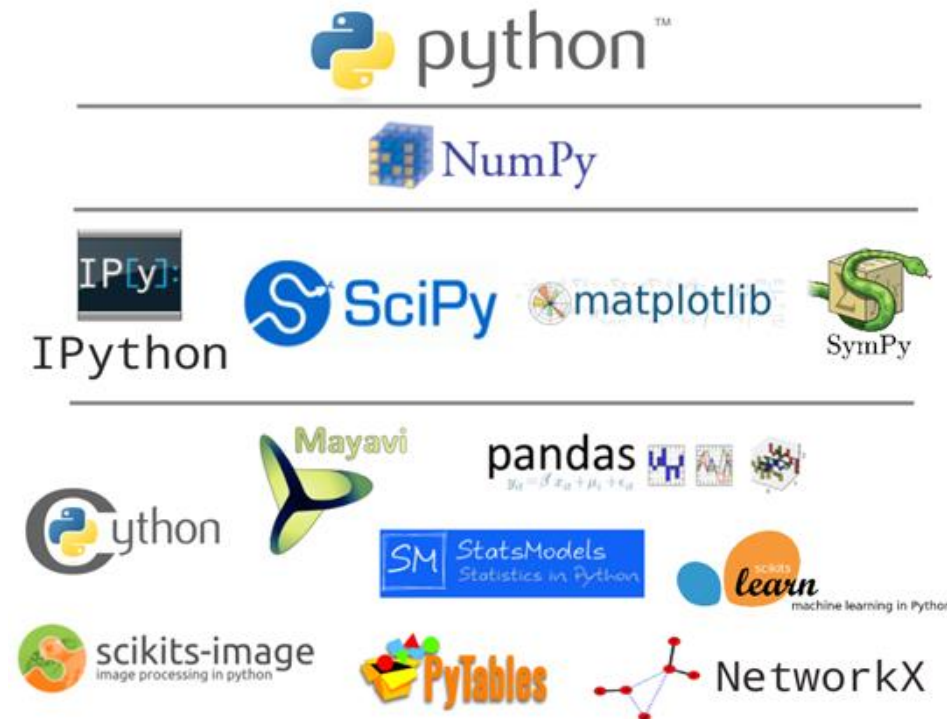
plt.figure(figsize = (10,8))
plt.plot(x, y_noise, 'o', label = 'dados original + ruido')
plt.plot(x, y, 'k', label = 'dados original')
plt.plot(x, yfit, '-r', label = 'curva ajustada com MLP', zorder = 10)
plt.legend()
plt.xlabel('X')
plt.ylabel('y')

# salva figura em arquivo
plt.savefig(mlp_regression.png)
```



Outras Bibliotecas Científicas

- Muitas outras possibilidades através do uso de diversas outras bibliotecas.
- Alguns exemplos:
 - **Pandas**: manipulação e análise de dados.
 - **SymPy**: manipulações simbólicas ao estilo *Mathematica*.
 - **AstroPy**: funcionalidades para astrônomos e astrofísicos.
 - **NetworkX**: usada para estudo de grafos e redes
 - etc.



Referências

- [1] Athanasios Papoulis and S. Pillai, “Probability - Random Variables and Stochastic Processes,” McGraw Hill Education; 4th ed., 2017.
- [2] Stuart Russell and Peter Norvig, “Artificial Intelligence: A Modern Approach,” Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [3] Aurélien Géron, “Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”, 1st ed., O'Reilly Media, 2017.
- [4] Joseph Misiti, “Awesome Machine-Learning,” on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [5] Andriy Burkov, “The Hundred-Page Machine-Learning Book,” Andriy Burkov 2019.
- [6] C. M. Bishop, “Pattern Recognition and Machine Learning,” Springer, 1st ed., 2006.
- [7] S. Haykin, “Neural Networks and Learning Machines,” Prentice Hall, 3ª ed., 2008.
- [8] Coleção pessoal de livros,
<https://drive.google.com/drive/folders/1lylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing>

Avisos


- Lista #0 já está disponível tanto no site quanto no MS Teams.
- Lista #1 será liberada ainda hoje.
- [Projeto Prático](#)
- Entregas devem ser feitas tanto no GitHub quanto no MS Teams.
 - Meu controle de entregas será via MS Teams e a correção será através do GitHub.
 - Se atentem às datas de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams e no site:
 - <https://www.inatel.br/docentes/felipefigueiredo/>
- Horário de Atendimento
 - Todas as Quintas-Feiras das 15:30 às 17:30 via MS Teams.

Perguntas?



Obrigado!



Dilbert.com DilbertCartoonist@gmail.com




2-2-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



Dilbert.com DilbertCartoonist@gmail.com



1-31-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



www.dilbert.com scottadams@aol.com



© 2003 United Feature Syndicate, Inc.



